

**MEMORIA JUSTIFICATIVA PARA LA ACEPTACIÓN
DEL ANTEPROYECTO**

**Modelo Geoespacial de Valoración
del Riesgo Climático**

Autor: Gonzalo Larriba

Universidad: FRANCISCO DE VITORIA

Grado: Bussiness analytics

Fecha: _____

INDICE

1. Descripción del problema a resolver	3
1.1 Motivación y origen	3
1.2 Datos que lo sustentan	3
1.3 Impacto de la solución.....	5
1.4 Problema de investigación	5
1.5 Preguntas de investigación	5
1.6 Planificación del proyecto.....	6
2. Estado del arte	6
2.2. Evidencia científica sobre riesgo climático y eventos extremos	7
2.3. Datos climáticos y geoespaciales en la literatura científica.....	8
2.4. Modelos científicos para evaluar riesgo climático	9
2.5. Aplicaciones en seguros: evidencia científica.....	10
2.6. Open Data en la modelización del riesgo.....	11
2.7. Brechas detectadas en la literatura	12
2.8. Conclusión del estado del arte.....	13
3. Objetivos.....	13
3.1 Objetivo general.....	13
3.2 Objetivos específicos.....	13
4. Metodología.....	14
5. Justificación de los modelos	14
6. Obtención de datos.....	15
7. Cronograma.....	16
8. Bibliografía	17

1. Descripción del problema a resolver

1.1 Motivación y origen

En las últimas décadas, se ha observado un aumento en la frecuencia e intensidad de fenómenos meteorológicos extremos, como lluvias torrenciales, inundaciones, temporales de viento, incendios forestales... en España y como en el resto del mundo, que afectan directamente a las viviendas y provocan un incremento en los siniestros de los seguros de hogar.

Para una aseguradora, esta realidad plantea varios retos: cómo cuantificar de forma adecuada el riesgo climático por zona, cómo ajustar la tarificación en función de ese riesgo, cómo gestionar la exposición de la cartera en áreas especialmente vulnerables y cómo implementar medidas de prevención que reduzcan la probabilidad y la gravedad de los siniestros.

La disponibilidad creciente de datos abiertos climáticos, geográficos y socioeconómicos, así como el avance de las técnicas de análisis geoespacial y de inteligencia artificial, permiten abordar este problema desde una perspectiva analítica avanzada, combinando información interna de siniestros con fuentes externas de alta resolución.

Además, durante este curso realizaré mis prácticas en MAPFRE, por lo que trabajar sobre un caso relacionado con seguros tiene especial sentido para mí. Esto me permitirá entender mejor cómo se aplican este tipo de modelos en un entorno real y enriquecer el proyecto con una visión más cercana al sector asegurador.

1.2 Datos que lo sustentan

El aumento de la frecuencia e intensidad de fenómenos atmosféricos en España en los últimos años hace necesario analizar cómo están afectando realmente al riesgo asegurador. Según AEMET (2024), España sigue una tendencia clara hacia un clima más cálido y variable. El 2022 fue el año más caluroso registrado y en 2024 la temperatura media volvió a estar muy por encima de lo normal. Ese año la precipitación alcanzó el 104 % del valor habitual y se dieron episodios muy intensos. También se registraron más de 352.000 descargas eléctricas en la Península y Baleares, y en zonas como el Pirineo oriental se superaron los 40 días de tormenta. Todo esto —calor extremo, lluvias fuertes y tormentas frecuentes— está directamente relacionado con el aumento de daños en viviendas.

Un ejemplo reciente es la DANA de octubre de 2024 en la Comunidad Valenciana, que dejó lluvias torrenciales y un impacto asegurador muy elevado.

Según la *Estadística de Riesgos Extraordinarios* del CCS (2024), la exposición asegurada también ha crecido mucho: en 2024 había 63,6 millones de pólizas consorciables y el capital asegurado superaba los 7,1 billones de euros). Este aumento implica que, con un clima más extremo, la vulnerabilidad económica potencial es cada vez mayor en las zonas con mayor concentración de riesgo.

Además, el IPCC (2021) confirma que la región mediterránea es especialmente vulnerable. Para España se prevé un aumento de temperatura de entre 1,2 °C y 3 °C, más variabilidad y lluvias intensas concentradas en menos tiempo, lo que incrementa el riesgo de inundaciones repentinas, tormentas más fuertes y daños por viento.

Para estudiar todo esto, el proyecto combina varias fuentes: datos climáticos (AEMET y ERA5), información geoespacial del IGN, datos territoriales del INE y Catastro, y siniestros agregados por zona. Con todo ello se construye un modelo geoespacial que relaciona el clima con la frecuencia y gravedad de los daños en el seguro de hogar.




Figura X.

Clasificación climática de España según anomalías de temperatura y precipitación (1961-2024).

Fuente: AEMET, *Informe sobre el estado del clima en España*.



Figura X. Evolución del número total de pólizas consorciables en España (millones).

Fuente: Consorcio de Compensación de Seguros (CCS), *Estadística de Riesgos Extraordinarios*.

1.3 Impacto de la solución

La elaboración de un modelo geoespacial para analizar y predecir el riesgo climático, puede aportar múltiples beneficios a una aseguradora, especialmente en el ramo de hogar.

Porque ayuda a identificar qué zonas son más propensas a sufrir daños cuando hay lluvias intensas, tormentas fuertes o incendios. Lo que permite tener una idea más clara del riesgo real que existe en cada área y no basarse solo en datos históricos generales.

Además, tener una estimación más precisa del riesgo facilita ajustar las primas de manera más coherente con la exposición de cada zona. Esto puede evitar problemas de infra tarificación y mejorar la estabilidad de la cartera, ya que los precios estarían más a la par de las características reales del territorio.

Otro punto importante es la prevención. Si la empresa sabe qué zonas tienen mayor probabilidad de verse afectadas por un fenómeno concreto, puede avisar a los clientes con antelación y recomendar medidas básicas, lo que reduce la posibilidad de que ocurra siniestros o, su gravedad.

El modelo también puede ayudar a nivel interno, en la gestión de cartera. Detectar áreas donde el riesgo está subiendo con el tiempo permite tomar decisiones estratégicas, como revisar su exposición o valorar la creación de productos específicos para esas zonas.

Por último, los resultados pueden representarse en mapas y cuadros de mando que facilitan la interpretación de los resultados. Esto convierte el modelo en una herramienta transversal útil para distintos equipos, incluidos mediadores, áreas técnicas y responsables de negocio.

1.4 Problema de investigación

¿Hasta qué punto las variables climáticas, geográficas y territoriales permiten estimar el riesgo climático en los seguros de hogar de manera útil para mejorar la tarificación y la gestión de la cartera?

1.5 Preguntas de investigación

¿Qué variables climáticas y geográficas influyen más en la aparición de siniestros en los seguros de hogar?

¿Existen patrones territoriales que permitan agrupar zonas con niveles de riesgo similares?

¿Hasta qué punto los datos abiertos pueden mejorar la precisión del modelo al combinarse con los datos internos de siniestros?

¿Qué técnicas de modelización funcionan mejor para estimar el riesgo climático a nivel geoespacial?

¿Cómo pueden representarse los resultados para que sean útiles en la toma de decisiones de tarificación, prevención y gestión de la cartera?

¿Hasta qué punto es posible predecir la ocurrencia de fenómenos atmosféricos adversos utilizando datos climáticos históricos, geoespaciales y registros reales de siniestros, considerando que su frecuencia e intensidad están aumentando debido al cambio climático?

1.6 Planificación del proyecto

El desarrollo del proyecto se organizará en varias fases consecutivas. En primer lugar, se llevará a cabo la recopilación de los datos necesarios, incluyendo tanto los registros internos de siniestros como las distintas fuentes de open data climática y geoespacial. A continuación, se realizará el proceso de preparación del dataset, que incluirá la limpieza, integración y transformación de las variables necesarias para el análisis.

Una vez tenga los datos listos, empezaré con la fase de modelización, probando distintos enfoques analíticos, como modelos basados en árboles y técnicas de clustering, con el objetivo de identificar patrones territoriales y estimar el nivel de riesgo climático asociado a cada zona. Posteriormente, elaboraré las visualizaciones, mapas y cuadros de mando que permitan interpretar los resultados y facilitar su aplicación práctica en decisiones de tarificación, prevención y gestión de cartera.

Finalmente, redactar el Trabajo de Fin de Grado y la preparación de la presentación para la defensa, integrando los resultados obtenidos y las conclusiones del estudio.

2. Estado del arte

El aumento de la frecuencia e intensidad de fenómenos atmosféricos en España en los últimos años hace necesario analizar cómo están abordando esta cuestión los estudios científicos y técnicos. En este estado del arte reviso las líneas principales de investigación que conectan clima, territorio y riesgo asegurador, organizadas en cuatro bloques. En primer lugar, analizo cómo la literatura describe la evolución del riesgo climático a nivel global y europeo, con especial atención al contexto español. En segundo lugar, reviso el uso de datos climáticos, geoespaciales y fuentes abiertas que permiten caracterizar el territorio y entender mejor la exposición al riesgo. En tercer lugar, recopiló las técnicas de modelización —tanto estadísticas como basadas en

machine learning— que se utilizan para predecir fenómenos ambientales y estimar siniestralidad. Por último, reviso las aplicaciones prácticas que ya se están empleando en el sector asegurador, especialmente en tarificación, prevención y gestión de cartera. Todo ello permite situar este proyecto dentro del trabajo académico existente y justificar la importancia de desarrollar un modelo geoespacial centrado específicamente en el seguro de hogar en España.

2.2. Evidencia científica sobre riesgo climático y eventos extremos

El aumento de la frecuencia e intensidad de los fenómenos atmosféricos en Europa está sólidamente documentado por la literatura científica. El IPCC AR6 (WGI) muestra que desde mediados del siglo XX los episodios de calor extremo se han vuelto *más frecuentes y más intensos* en la mayoría de regiones terrestres (A.3.1), mientras que las *precipitaciones intensas* han aumentado en buena parte de las zonas con datos consistentes (A.3.2). A esto se suma el incremento de las *sequías agrícolas y ecológicas* en varias regiones del planeta (A.3.5), un patrón que afecta especialmente a climas mediterráneos como el español. Además, el IPCC estima que las precipitaciones extremas se intensifican alrededor de un 7 % *por cada grado de calentamiento global* (B.2.4), lo que significa que incluso incrementos moderados de temperatura tienen efectos desproporcionados sobre el riesgo de inundaciones y daños asociados.

Estos cambios no solo se observan a nivel físico, sino también en sus impactos sobre sociedades y territorios. El IPCC AR6 (WGII) señala que el cambio climático ya está generando impactos adversos generalizados, con pérdidas ambientales y económicas en numerosos sistemas humanos (B.1). La región mediterránea destaca como una de las áreas más vulnerables, con efectos claros sobre la disponibilidad de agua y la estabilidad de los ecosistemas (B.2). Las ciudades e infraestructuras del sur de Europa —incluidas las áreas urbanas españolas— están cada vez más expuestas a olas de calor, inundaciones repentinas y sequías persistentes (B.3). Además, el IPCC advierte que *cada incremento adicional del calentamiento global aumenta los riesgos para la población, ecosistemas e infraestructuras* (C.2), y que en partes del Mediterráneo ya se están alcanzando *límites de adaptación* (D.2), lo que incrementa la vulnerabilidad futura.

La evidencia observacional reciente confirma este escenario. El informe European State of the Climate 2023, elaborado por Copernicus y la Organización Meteorológica Mundial, muestra que Europa se está calentando aproximadamente *el doble de rápido* que la media global, con veranos excepcionalmente cálidos y episodios generalizados de *estrés térmico extremo* en el sur del continente (Summary ESOTC 2023, pp. 4–6). También se registraron algunas de las mayores inundaciones y crecidas fluviales documentadas, como las de Italia, Eslovenia o Grecia, donde llegó a precipitar en un solo día el equivalente a un año completo de lluvia. A ello se suman incendios de magnitud histórica —como el de Grecia, el mayor jamás registrado en la Unión Europea— y desequilibrios hidrológicos que afectan a buena parte de la Península Ibérica. Este conjunto de fenómenos evidencia una intensificación del riesgo climático a escala continental.

En conjunto, la literatura científica coincide en que Europa, y especialmente la cuenca mediterránea, está entrando en un régimen climático caracterizado por una mayor variabilidad y una frecuencia creciente de fenómenos extremos: olas de calor más intensas, sequías más severas, precipitaciones extremas más frecuentes e incendios de gran magnitud. La convergencia entre las

conclusiones del IPCC AR6 y los análisis recientes de Copernicus refuerza la idea de que el riesgo físico está aumentando con claridad y que sus impactos serán cada vez más relevantes para sectores como el asegurador, donde la exposición a daños asociados a fenómenos atmosféricos extremos constituye un desafío creciente.




Figura X. Eventos extremos registrados en Europa durante 2023.

Fuente: Copernicus Climate Change Service & WMO, European State of the Climate 2023 (Summary, p. 4).

2.3. Datos climáticos y geoespaciales en la literatura científica

La literatura científica pone de relieve la importancia de los datos climáticos y geoespaciales para el análisis ambiental y la evaluación del riesgo asociado a fenómenos extremos. Entre las fuentes más utilizadas se encuentran los conjuntos de datos de reanálisis, que permiten reconstruir de forma coherente la evolución del clima a partir de observaciones y modelos numéricos. En este contexto, ERA5, desarrollado por el ECMWF dentro del programa Copernicus, se ha consolidado como una referencia estándar en estudios científicos. Según Hersbach et al. (2020), ERA5 proporciona series temporales continuas de variables atmosféricas como temperatura, precipitación, viento o humedad, con alta resolución espacial y temporal, y ha sido ampliamente empleado en evaluaciones climáticas y trabajos utilizados por el propio IPCC.

De manera complementaria, numerosos estudios incorporan datos satelitales para captar la heterogeneidad espacial del territorio. Las misiones Sentinel de la Agencia Espacial Europea, y en particular Sentinel-2, ofrecen imágenes ópticas multiespectrales de alta resolución que permiten analizar la cobertura del suelo, la vegetación y los cambios en el uso del territorio. Tal como describen Drusch et al. (2012), estos datos se utilizan de forma sistemática en aplicaciones ambientales y de gestión territorial. A partir de estas imágenes se derivan indicadores clave como el NDVI (Normalized Difference Vegetation Index), ampliamente empleado para representar el estado y la densidad de la vegetación. La literatura científica reconoce el NDVI como una variable geoespacial relevante en estudios ambientales, al estar relacionada con procesos como incendios, sequías o erosión, tal y como señalan Pettorelli et al. (2005).

En el ámbito de la superficie terrestre, el reanálisis ERA5-Land amplía las capacidades de ERA5 al proporcionar información climática a mayor resolución espacial, especialmente orientada a aplicaciones sobre el suelo, como la humedad, la temperatura del terreno o el balance hídrico. Según Muñoz-Sabater et al. (2021), ERA5-Land se ha convertido en una fuente clave para estudios geoespaciales que requieren una representación detallada de las interacciones entre clima y territorio, siendo especialmente útil en análisis regionales y locales.

Finalmente, la integración de estos datos climáticos y geográficos se realiza habitualmente mediante Sistemas de Información Geográfica (GIS). La literatura muestra que el uso combinado de variables climáticas, topográficas y territoriales dentro de entornos GIS constituye una práctica consolidada en estudios de riesgos naturales. Por ejemplo, Samela et al. (2017) aplican un enfoque basado en GIS para la evaluación de la peligrosidad por inundaciones, integrando información hidrológica, topográfica y espacial. Este tipo de aproximaciones refuerza la idea de que la combinación de datos climáticos, variables geoespaciales y herramientas GIS conforma un marco metodológico ampliamente aceptado en la investigación científica sobre riesgos ambientales.

2.4. Modelos científicos para evaluar riesgo climático

La literatura científica subraya que la evaluación del riesgo climático requiere modelos capaces de capturar la heterogeneidad espacial del territorio, dado que la relación entre variables climáticas, geográficas y de impacto no es uniforme. En este contexto, los modelos espaciales, como la *Geographically Weighted Regression* (GWR) y sus extensiones multiescala, permiten estimar relaciones locales entre variables, evitando la asunción de coeficientes constantes en todo el espacio. En particular, la regresión geográficamente ponderada multiescala (MGWR) introduce la posibilidad de que cada variable opere a una escala espacial distinta, mejorando la representación de procesos territoriales complejos. Este enfoque ha sido formalizado y aplicado en la literatura reciente, tal y como describen Oshan et al. (2019, Introduction y Methods), consolidándose como una herramienta relevante en estudios espaciales de riesgo ambiental.

Junto a los modelos espaciales, los enfoques de machine learning basados en árboles de decisión, como Random Forest o XGBoost, se han empleado de forma creciente en estudios de riesgo climático, especialmente en el análisis de inundaciones. Estos modelos destacan por su capacidad para manejar relaciones no lineales y grandes volúmenes de variables climáticas y territoriales sin

necesidad de supuestos paramétricos estrictos. Revisiones de la literatura muestran que estos algoritmos se utilizan ampliamente para la predicción de inundaciones, integrando información hidrológica, meteorológica y geoespacial, y que suelen ofrecer un buen rendimiento predictivo frente a métodos tradicionales (Mosavi et al., 2018, Literature Review).

En el ámbito de los incendios forestales, la literatura más reciente pone de manifiesto un creciente uso combinado de técnicas de *machine learning* y *deep learning* para predecir la propagación y el riesgo asociado. Estudios de revisión actuales recogen la aplicación de algoritmos como Random Forest o XGBoost, junto con arquitecturas de redes neuronales profundas como CNN y LSTM, capaces de capturar patrones espaciales y temporales complejos. Estos modelos integran variables climáticas, territoriales y de vegetación, permitiendo una aproximación más realista al riesgo de incendios (Andrianarivony & Akhloufi, 2024, Introduction; Sections 2–4). De forma complementaria, revisiones de alto nivel destacan el potencial del *deep learning* en las ciencias del clima para modelizar sistemas no lineales y eventos extremos, aunque también señalan retos asociados a la interpretabilidad de los modelos (Reichstein et al., 2019, Introduction; Applications).

Finalmente, una línea de investigación emergente enfatiza la necesidad de modelos integrados que combinen simultáneamente clima, territorio y técnicas avanzadas de modelización. En este sentido, el concepto de eventos climáticos compuestos resulta clave para entender el riesgo real, ya que muchos impactos relevantes surgen de la interacción de múltiples factores, como precipitaciones extremas sobre suelos saturados o episodios de calor combinados con sequía. La literatura muestra que analizar estos fenómenos de forma aislada puede infraestimar el riesgo, reforzando la necesidad de enfoques multivariantes e integrados (Zscheischler et al., 2018, Introduction; Compound events and impacts; Discussion). Este marco resulta especialmente pertinente para aplicaciones orientadas a la evaluación del riesgo y la toma de decisiones en contextos territoriales complejos.

2.5. Aplicaciones en seguros: evidencia científica

La literatura técnica del sector asegurador muestra de forma consistente que el incremento del riesgo climático tiene un impacto directo sobre la siniestralidad. Informes recientes del Swiss Re Institute señalan que las catástrofes naturales asociadas a fenómenos climáticos extremos han generado pérdidas económicas y aseguradas crecientes en los últimos años, superando en 2023 los valores medios de la última década. En particular, el informe *sigma 1/2024* documenta un aumento tanto en la frecuencia de eventos extremos como en las pérdidas aseguradas asociadas, lo que pone de manifiesto la creciente exposición del sector asegurador a riesgos de origen climático (Swiss Re Institute, *sigma 1/2024*, Executive Summary).

Desde una perspectiva complementaria, Munich Re, a través de su base de datos NatCatSERVICE, proporciona evidencia empírica detallada sobre la evolución histórica de las catástrofes naturales y sus impactos económicos y asegurados desde 1980. Los registros de NatCatSERVICE muestran que los eventos meteorológicos, hidrológicos y climatológicos — como inundaciones, tormentas e incendios — concentran una parte sustancial de las pérdidas aseguradas a nivel global. El mapa de eventos de pérdidas por catástrofes de 2023 ilustra

claramente la distribución espacial de estos eventos y su relevancia para el negocio asegurador, reforzando el papel de estas bases de datos como soporte clave para la modelización del riesgo y la gestión de carteras (Munich Re, NatCatSERVICE, *Nat cat loss events 2023*).

Por último, tanto organismos sectoriales como reguladores subrayan la necesidad de integrar de forma sistemática el riesgo climático en la toma de decisiones aseguradoras. The Geneva Association, en su informe *Climate Risk 3*, destaca que las aseguradoras deben adoptar enfoques holísticos que incorporen riesgos físicos y de transición en procesos como la tarificación, el underwriting y la gestión de cartera (The Geneva Association, 2022, *Climate Risk 3 Summary*). En la misma línea, EIOPA considera el riesgo físico derivado del cambio climático como un riesgo material para el sector asegurador europeo, señalando su impacto potencial sobre la siniestralidad, la solvencia y la estabilidad financiera, y enfatizando la necesidad de mejorar los datos y modelos empleados en su evaluación (EIOPA, *Discussion paper on physical climate change risks, Impacts on insurance undertakings*).




Figura X. Principales eventos de pérdidas por catástrofes naturales a nivel global en 2023.
 Fuente: Munich Re, NatCatSERVICE, *Nat cat loss events 2023*.

2.6. Open Data en la modelización del riesgo

La literatura científica pone de manifiesto el papel creciente de las fuentes de datos abiertos (Open Data) en la modelización del riesgo climático, impulsado en gran medida por iniciativas institucionales como el Copernicus Climate Change Service (C3S). A través del Climate Data Store (CDS), Copernicus proporciona acceso abierto y gratuito a conjuntos de datos climáticos que incluyen observaciones, reanálisis y proyecciones, facilitando su uso en investigación científica y análisis de riesgos. Entre estos conjuntos de datos destaca el reanálisis ERA5, descrito por Hersbach et al. (2020), que se ha convertido en una referencia ampliamente utilizada para el estudio de variables climáticas como la temperatura, la precipitación o el viento, gracias a su cobertura global y consistencia temporal.

El uso de Open Data ofrece ventajas relevantes en el contexto de la modelización del riesgo. En particular, permite mejorar la transparencia de los análisis, favorece la reproducibilidad de los resultados y facilita la comparación entre estudios realizados en distintos territorios. No obstante, la literatura también señala limitaciones importantes, relacionadas principalmente con la resolución espacial relativamente agregada de algunos conjuntos de datos o con la dificultad para capturar procesos locales específicos. Estas limitaciones implican que, aunque los datos abiertos constituyen una base sólida para el análisis del riesgo climático, su aplicación requiere un tratamiento metodológico cuidadoso y, en determinados casos, la combinación con información adicional a escalas más detalladas (Copernicus Climate Change Service, Climate Data Store).

En este sentido, diversos estudios subrayan la importancia de integrar datos procedentes de múltiples fuentes para obtener una visión más completa del riesgo. Trabajos como el de Jongman et al. (2014) combinan datos climáticos con información geográfica y socioeconómica para analizar la exposición y los impactos asociados a eventos extremos, mostrando que el riesgo no depende únicamente de la peligrosidad climática, sino también de factores territoriales y de la concentración de activos. Este tipo de enfoques integrados, apoyados en el uso de Open Data, resulta clave para avanzar hacia modelos de riesgo más realistas y útiles en contextos de toma de decisiones.

2.7. Brechas detectadas en la literatura

La revisión de la literatura pone de manifiesto que, a pesar de los avances recientes en el análisis del riesgo climático, sigue existiendo una fragmentación importante entre los distintos enfoques empleados. Muchos trabajos analizan el clima, el territorio o la modelización estadística de forma aislada, pero son escasos los estudios que integran de manera conjunta variables climáticas, información geoespacial y técnicas de machine learning dentro de un marco aplicado específicamente al sector asegurador.

Asimismo, una limitación recurrente en los estudios revisados es la resolución espacial de los modelos utilizados. Gran parte de la literatura trabaja a escalas regionales o nacionales, lo que dificulta la identificación precisa del riesgo a nivel local. Esta falta de detalle espacial reduce la utilidad práctica de los modelos en contextos como el seguro de hogar, donde el riesgo está fuertemente condicionado por características muy específicas del entorno y de la localización de los activos asegurados.

Por otro lado, aunque el potencial de las fuentes de Open Data ha sido ampliamente reconocido en el ámbito académico, su uso en aplicaciones reales del sector asegurador sigue siendo limitado. Existe una brecha clara entre los desarrollos metodológicos propuestos en la literatura científica y su implementación efectiva en procesos operativos como la tarificación, la suscripción o la gestión de carteras, lo que pone de relieve la necesidad de enfoques más aplicados.

Otra carencia relevante es la escasa atención a la interpretabilidad de los modelos. Muchos estudios basados en técnicas de machine learning se centran en mejorar la capacidad predictiva, pero ofrecen poca información sobre el papel de las distintas variables en la estimación del riesgo. Esta falta de explicabilidad supone una limitación importante en el ámbito asegurador, donde la

transparencia y la comprensión de los resultados son elementos clave para la toma de decisiones y el cumplimiento regulatorio.

Finalmente, la literatura revisada muestra una ausencia de modelos específicamente orientados al seguro de hogar en España que integren de forma conjunta clima, territorio y técnicas avanzadas de modelización. La mayoría de los trabajos se centran en otros países o en análisis agregados, lo que refuerza la necesidad de desarrollar modelos adaptados al contexto español y con una clara orientación a su aplicación práctica en el sector asegurador.

2.8. Conclusión del estado del arte

La literatura científica revisada muestra un amplio consenso en torno al aumento de la frecuencia e intensidad de los fenómenos climáticos extremos y a su impacto creciente sobre el territorio y los sistemas socioeconómicos, así como en la utilidad de los datos climáticos, geoespaciales y de técnicas avanzadas de modelización para evaluar el riesgo asociado. Sin embargo, también pone de manifiesto importantes carencias, como la falta de enfoques integrados que combinen de forma conjunta clima, territorio y métodos de machine learning, la limitada resolución espacial de muchos estudios, el uso todavía incipiente de fuentes de Open Data en aplicaciones aseguradoras reales y la escasa atención a la interpretabilidad de los modelos. Además, se observa una ausencia de trabajos específicamente orientados al seguro de hogar en España que aborden estas cuestiones de manera aplicada. En este contexto, el presente Trabajo Fin de Grado se sitúa como una contribución orientada a cubrir estas brechas, mediante el desarrollo de un modelo geoespacial de valoración del riesgo climático que integre datos abiertos, variables territoriales y técnicas de machine learning, con un enfoque específico en el seguro de hogar y con el objetivo de aportar resultados interpretables y relevantes para la toma de decisiones en el sector asegurador.

3. Objetivos

3.1 Objetivo general

“Desarrollar un modelo preliminar que permita analizar la relación entre variables climáticas/geográficas y la siniestralidad, explorando posibles aplicaciones en el ámbito asegurador.”

3.2 Objetivos específicos

Demostrar el valor que aportan las fuentes OPEN DATA disponibles por parte de organismos gubernamentales y asociaciones

Demostrar como el creciente numero de fenómenos atmosféricos relacionados con el cambio climático hacen fundamental disponer de modelos como el planteado en el trabajo.

Explorar de qué manera un modelo de este tipo podría contribuir a mejorar la experiencia del cliente, las acciones preventivas y la personalización de servicios en el ámbito asegurador.

4. Metodología

La modelización del riesgo climático se llevará con un enfoque combinado, orientado tanto al análisis de la relación entre variables climáticas, geográficas y territoriales y la siniestralidad, como a la identificación de patrones territoriales de riesgo. Todo el proceso de análisis y modelización se desarrollará en Python, utilizando VS Code como entorno principal de trabajo.

En primer lugar, se usara Random Forest como modelo predictivo principal. Este modelo se utilizará para analizar la relación existente entre las variables climáticas, geográficas y territoriales y la siniestralidad en el seguro de hogar. Su elección se debe a su capacidad para capturar relaciones no lineales y manejar interacciones complejas entre variables, características habituales en el análisis de fenómenos climáticos y territoriales. En este trabajo, el objetivo del modelo no será únicamente la predicción, sino principalmente el análisis de la capacidad explicativa de las variables y su influencia relativa en el riesgo.

De forma complementaria, se aplicarán técnicas de clustering territorial, utilizando principalmente K-means, con el objetivo de identificar zonas geográficas homogéneas en términos de exposición al riesgo climático. Este enfoque permitirá detectar patrones espaciales y segmentar el territorio en áreas con características similares, lo que resulta especialmente útil en un análisis exploratorio del riesgo a escala local.

También, se podrá emplear DBSCAN de manera exploratoria para la detección de posibles concentraciones espaciales de riesgo o *hotspots* climáticos, sin necesidad de imponer un número previo de grupos. Su uso tendrá un carácter complementario y permitirá contrastar los resultados obtenidos mediante K-means.

Los modelos se evaluarán atendiendo principalmente a su estabilidad y capacidad explicativa, más que a un objetivo puramente predictivo, en coherencia con el carácter preliminar del trabajo.

5. Justificación de los modelos

Los modelos seleccionados se justifican por su adecuación al objetivo del proyecto y por su uso consolidado en el análisis del riesgo climático y en el sector asegurador.

- Random Forest se emplea para analizar la relación entre variables climáticas, geográficas y territoriales y la siniestralidad, permitiendo identificar qué factores influyen en mayor medida en el riesgo y capturar relaciones no lineales habituales en este tipo de fenómenos.

- K-means, como técnica principal de clustering, se utiliza para segmentar el territorio en zonas homogéneas de riesgo climático, facilitando la identificación de patrones espaciales y la comparación entre distintas áreas geográficas.
- DBSCAN se utiliza de forma exploratoria para detectar concentraciones espaciales de riesgo, permitiendo identificar posibles *hotspots* sin imponer una estructura previa al territorio.
- SHAP se emplea como técnica de interpretabilidad para facilitar la comprensión de los resultados del modelo predictivo y permitir su comunicación a perfiles no técnicos dentro del sector asegurador.

La visualización final de los resultados se realizará mediante Power BI, con el objetivo de representar los patrones de riesgo identificados de forma clara e intuitiva para perfiles de negocio, mediadores y responsables técnicos.

A continuación, se describen las fuentes de datos empleadas y los procedimientos seguidos para su obtención, con el objetivo de garantizar la reproducibilidad del análisis.

6. Obtención de datos

Para obtener los datos climáticos a escala local he utilizado la API oficial de AEMET OpenData, que ofrece información meteorológica pública y reutilizable. El acceso se realiza mediante una API Key personal obtenida tras registrarme en el portal de AEMET; por seguridad la clave no se incluye en la entrega.

- **Herramienta:** API REST de AEMET
- **Método:** descarga directa mediante solicitudes HTTP
- **Autenticación:** API Key personal (no incluida por motivos de seguridad)
- **Tipo de datos:** predicción meteorológica diaria a nivel municipal (JSON)
- **Archivo incluido:** AEMET_Madrid_original.json (dato original, sin modificar)

Para datos a escala global he recurrido al Copernicus Climate Data Store (CDS), usando reanálisis como ERA5, que permiten trabajar con series climáticas históricas y recientes de forma homogénea.

La descarga se ha automatizado con la librería oficial cdsapi, que utiliza un archivo de configuración local para la autenticación.

- **Herramienta:** API del Climate Data Store (CDS) mediante cdsapi
- **Método:** solicitud programática con el cliente oficial en Python

- **Autenticación:** clave personal gestionada mediante el archivo .cdsapirc (no incluida por motivos de seguridad)
- **Tipo de datos:** reanálisis ERA5 — temperatura a 2 m, resolución horaria
- **Formato:** NetCDF (.nc)
- **Archivos incluidos:** temperatura_era5.nc (dato original, sin modificar) y descarga_era5.py (script usado para la descarga)

Los datos originales y los scripts de descarga están disponibles en el repositorio en la nube cuyo enlace figura en este documento. Todos los ficheros se conservan en su formato original y no han sido modificados tras su obtención.

<https://onedrive.live.com/?redeem=aHR0cHM6Ly8xZHJ2Lm1zL2YvYy8yYjNjODBkYjJjZGYxMDBiL0lnQTdBajNPajJ6UVJKaDBRSVppbnFRUkFhcFZMb1RRdVZ0ZjR1cnZydDIUTk1ZP2U9Skg4U3ZI&id=2B3C80DB2CDF100E%21sce3d023b1c8d44d098744086629ea411&cid=2B3C80DB2CDF100E>

7. Cronograma

El proyecto se desarrollará en varias fases consecutivas, con una planificación estimada en semanas.

Fase 0. Anteproyecto

Elaboración y revisión del anteproyecto. Reentrega: **15 de diciembre**.

Fase 1. Ingeniería de datos (3 semanas)

Obtención, limpieza e integración de datos climáticos y geoespaciales.

Fase 2. Análisis exploratorio (2/3 semanas)

Identificación de patrones y relaciones relevantes entre variables.

Fase 3. Desarrollo de modelos (4 semanas)

Implementación de modelos analíticos y técnicas de clustering para la estimación del riesgo climático.

Fase 4. Validación y comparación (2/3 semanas)

Evaluación de resultados y selección del modelo más adecuado.

Fase 5. Análisis de negocio (2/3 semanas)

Interpretación de resultados, visualizaciones y generación de recomendaciones.

Fase 6. Redacción y entrega final (2 semanas)

Redacción del TFG y preparación de la defensa.

8. Bibliografía

AEMET

Agencia Estatal de Meteorología. (2024). *Informe sobre el estado del clima en España (2024,2022)*.

https://www.aemet.es/es/conocermas/recursos_en_linea/publicaciones_y_estudios/publicaciones/detalles/informe_estado_clima

Consorcio de Compensación de Seguros (CCS)

Consorcio de Compensación de Seguros. (2024). *Estadística de riesgos extraordinarios*.

<https://www.conorseguros.es/la-entidad/publicaciones>

Consorcio de Compensación de Seguros..

Estadística de riesgos extraordinarios 1971–2014.

https://www.conorseguros.es/documents/10184/44193/Estadistica_Riesgos_Extraordinarios_1971_2014/14ca6778-2081-4060-a86d-728d9a17c522

IPCC AR6 – WGII (Mediterráneo / España)

IPCC. (2021). *AR6 Working Group II – Regional Fact Sheet: Europe & Mediterranean*.

Intergovernmental Panel on Climate Change.

https://www.ipcc.ch/report/ar6/wg2/downloads/report/IPCC_AR6_WGII_CCP4_SM.pdf

Copernicus / ERA5

Copernicus Climate Change Service. (2024). *ERA5 reanalysis dataset*. European Centre for Medium-Range Weather Forecasts (ECMWF).

<https://cds.climate.copernicus.eu/>

Instituto Geográfico Nacional

Instituto Geográfico Nacional & Centro Nacional de Información Geográfica. (2024). *Datos geoespaciales oficiales de España*.

<https://www.ign.es>

Instituto Nacional de Estadística

Instituto Nacional de Estadística. (2024). *Base de datos estadísticos de España*.

<https://www.ine.es>

Catastro

Dirección General del Catastro. (2024). *Sede Electrónica del Catastro*.
<https://www.sedecatastro.gob.es>

IPCC – Working Group I (clima físico)

Intergovernmental Panel on Climate Change. (2021). *Climate Change 2021: The Physical Science Basis. Summary for Policymakers*. Cambridge University Press.
<https://www.ipcc.ch/report/ar6/wg1/>

IPCC – Working Group II (impactos y vulnerabilidad)

Intergovernmental Panel on Climate Change. (2022). *Climate Change 2022: Impacts, Adaptation and Vulnerability. Summary for Policymakers*. Cambridge University Press.
<https://www.ipcc.ch/report/ar6/wg2/>

Copernicus / WMO – Evidencia observacional reciente en Europa

Copernicus Climate Change Service & World Meteorological Organization. (2023). *European State of the Climate 2023: Summary*.
https://climate.copernicus.eu/sites/default/files/custom-uploads/ESOTC%202023/Summary_ESOTC2023.pdf

Hersbach, H., Bell, B., Berrisford, P., Hirahara, S., Horányi, A., Muñoz-Sabater, J., ... Thépaut, J.-N. (2020).

The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730), 1999–2049.
<https://doi.org/10.1002/qj.3803>

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., ... Bargellini, P. (2012).

Sentinel-2: ESA's optical high-resolution mission for GMES operational services. *Remote Sensing of Environment*, 120, 25–36.
<https://doi.org/10.1016/j.rse.2011.11.026>

Muñoz-Sabater, J., Dutra, E., Agustí-Panareda, A., Albergel, C., Arduini, G., Balsamo, G., ... Thépaut, J.-N. (2021).

ERA5-Land: A state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data*, 13(9), 4349–4383.

<https://doi.org/10.5194/essd-13-4349-2021>

Pettorelli, N., Vik, J. O., Mysterud, A., Gaillard, J.-M., Tucker, C. J., & Stenseth, N. C. (2005).

Using the normalized difference vegetation index (NDVI) to assess ecological responses to environmental change. *Trends in Ecology & Evolution*, 20(9), 503–510.

<https://doi.org/10.1016/j.tree.2005.05.011>

Samela, C., Albano, R., Sole, A., & Manfreda, S. (2017).

A GIS-based approach for flood hazard assessment. *Natural Hazards*, 87(3), 1401–1418.

<https://doi.org/10.1007/s11069-017-2814-1>

Oshan, T. M., Li, Z., Kang, W., Wolf, L. J., & Fotheringham, A. S. (2019).

MGWR: A Python implementation of multiscale geographically weighted regression for investigating process spatial heterogeneity and scale. *ISPRS International Journal of Geo-Information*, 8(6), 269.

<https://doi.org/10.3390/ijgi8060269>

Mosavi, A., Ozturk, P., & Chau, K.-W. (2018).

Flood prediction using machine learning models: Literature review. *Water*, 10(11), 1536.

<https://doi.org/10.3390/w10111536>

(si prefieres dejar solo el enlace de ResearchGate en el anteproyecto, también es válido)

Andrianarivony, M., & Akhloufi, M. (2024).

Machine learning and deep learning for wildfire spread prediction: A review. *Fire*, 7(12), 482.

<https://doi.org/10.3390/fire7120482>

Reichstein, M., Camps-Valls, G., Stevens, B., Jung, M., Denzler, J., Carvalhais, N., & Prabhat. (2019).

Deep learning and process understanding for data-driven Earth system science. *Nature*,

566(7743), 195–204.

<https://doi.org/10.1038/s41586-019-0912-1>

Zscheischler, J., Westra, S., van den Hurk, B. J. J. M., Seneviratne, S. I., Ward, P. J., Pitman, A., ... Zhang, X. (2018).

Future climate risk from compound events. *Nature Climate Change*, 8(6), 469–477.

<https://doi.org/10.1038/s41558-018-0156-3>

Swiss Re Institute. (2024).

Natural catastrophes and insurance losses in 2023: A record year for losses (Sigma No. 1/2024).

<https://www.swissre.com/institute/research/sigma-research/sigma-2024-01.html>

Munich Re. (2023).

Nat cat loss events 2023: Natural catastrophes caused overall losses of US\$ 250bn worldwide.

<https://www.munichre.com/content/dam/munichre/mrwebsitesspressreleases/MunichRe-NatCat-2023-world-map.pdf>

Munich Re. (n.d.).

NatCatSERVICE: Data on natural disasters since 1980.

<https://www.munichre.com/en/solutions/for-industry-clients/natcatservice.html>

The Geneva Association. (2022).

Climate Risk 3: Managing physical climate risks (Summary report).

https://www.genevaassociation.org/sites/default/files/2022-10/Climate%20Risk%203_Summary_web.pdf

European Insurance and Occupational Pensions Authority (EIOPA). (2022).

Discussion paper on physical climate change risks.

https://www.eiopa.europa.eu/document/download/9dfd30fc-d5f6-4c78-8467-4546603ba7df_en

Copernicus Climate Change Service. (n.d.).

Climate Data Store.

<https://cds.climate.copernicus.eu/>

Copernicus Climate Change Service. (n.d.).

Copernicus Climate Change Service (C3S).

<https://climate.copernicus.eu/>

**Hersbach, H., Bell, B., Berrisford, P., Hirahara, S., Horányi, A., Muñoz-Sabater, J., ...
Thépaut, J.-N. (2020).**

The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730), 1999–2049.

<https://doi.org/10.1002/qj.3803> (La uso en dos bloques del estado del arte)

Jongman, B., Ward, P. J., & Aerts, J. C. J. H. (2014).

Global exposure to river and coastal flooding: Long-term trends and changes. *Natural Hazards and Earth System Sciences*, 14(5), 1245–1261.

<https://doi.org/10.5194/nhess-14-1245-2014>