

El dato mata al relato.

- Refrán popular

*Dedicado a todas esas personas que me han acompañado durante el camino
y han hecho esto posible.*

Agradecimientos

Después de terminar este proyecto, y contando los días para dar por finalizado el grado, solo tengo palabras de agradecimiento hacia todas las personas que me han acompañado en el camino:

Palabras de AGRADECIMIENTO con mayúsculas a mis padres. Agradecido por haberme permitido elegir, por haber confiado en mí y por haberme apoyado en todas mis decisiones.

También quiero agradecer a mi hermana, Isabel, que siempre ha buscado ayudarme y hacerme las cosas más fáciles.

A mi tutor, el Dr. Adolfo Nadal, y a la Dra. Ana Lazcano, por introducirme en este maravilloso campo, por su ayuda desinteresada y cercana, y sin la que todo esto hubiera sido mucho más difícil.

Al Dr. Manuel Monge y al Dr. Alberto López Rosado, por su generosidad al ofrecer su ayuda.

A todas las personas que han estado en mi camino, amigos y compañeros, porque sin todos ellos nada hubiera sido igual.

Por último y más importante, a aquellas personas que junto con las que inicié el camino, pero que ahora ya no siguen aquí. Estoy convencido que estarán profundamente orgullosos de ver finalizada esta etapa de mi vida.

Resumen

Recientemente, el mercado de vehículos eléctricos en todas sus variables ha experimentado un auge incentivado por diversos factores. En este proyecto se presenta el precio del Litio como factor diferencial del precio de venta al público del vehículo eléctrico y es por ello por lo que se presenta una predicción del precio de esta materia prima, dando como resultado el análisis de la tendencia de los valores predichos y su extrapolación al P.V.P. del vehículo eléctrico.

Asimismo, la labor de concienciación que se busca con la democratización de la información obtenida durante la elaboración del proyecto es fundamental para la consecución de los objetivos propuestos por la Unión Europea: conseguir neutralidad climática para el año 2050.

Palabras claves

Predicción de series temporales, Machine Learning, Litio, Pacto Verde Europeo, Objetivo 55, vehículo eléctrico.

Abstract

Recently, the electric vehicle market in all its variables has experienced a growth encouraged by various factors. In this project, the price of Lithium is presented as a differential factor of the electric vehicle retail price. That is why a forecast based on the worth of this raw material is presented, resulting in a trend analysis of the values predicted and its extrapolation to the electric vehicle retail price.

Therefore, the efforts of raising awareness that are sought with the democratization of the information obtained during the project preparation are key for the achievement of the objectives proposed by the European Union: to reach climate neutrality by the year 2050.

Keywords

Time series prediction, Machine Learning, Lithium, European Green Deal, Fit for 55, electric vehicle.

Índice de Contenidos

1. Introducción	1
1.1. Descripción del problema	1
1.2. Motivación del trabajo.....	1
1.3. Organización de la memoria	2
2. Investigación previa	3
2.1. Estado del arte	3
2.2. Marco legal	6
2.2.1. Legislación europea.....	6
2.2.2. Legislación española.....	10
2.3. Marco técnico	11
2.3.1. Series temporales.....	11
2.3.2. Modelos matemáticos.....	12
2.4. Descripción del conjunto de datos en el caso de estudio	19
2.4.1. Descripción de variables.....	19
2.5. Criterios de desempeño.....	20
2.5.1. Métricas de evaluación	20
2.5.2. Pruebas de comprobación de estacionariedad.....	21
2.5.3. Criterios para la obtención del mejor orden ARIMA.....	23
3. Objetivos	25
3.1. Objetivo general.....	25
3.2. Objetivos específicos	25
4. Plan de Desarrollo del Proyecto	27
4.1. Metodología.....	27
4.2. Tecnologías	30
4.2.1. Python	30
4.2.2. Google Colaboratory	31
4.3. Plan de trabajo.....	31
4.4. Desviaciones del plan inicial	33

4.5.	Recursos	34
4.6.	Condiciones y Limitaciones	34
5.	Desarrollo de la Solución Técnica	35
5.1.	Preprocesamiento de datos	35
5.1.1.	Elección de variables características	35
5.1.2.	Tratamiento de valores nulos.....	36
5.2.	Análisis de la serie temporal	37
5.2.1.	Representación de la serie temporal	37
5.2.2.	Descomposición de la serie temporal	38
5.2.3.	Comprobación de la estacionariedad de la serie temporal	39
5.3.	Predicción con modelo Prophet	39
5.4.	Predicción con modelo SARIMAX.....	40
5.4.1.	Validación del modelo	43
6.	Resultados.....	47
6.1.	Resultados del método Prophet.....	47
6.2.	Resultados del método SARIMAX.....	48
6.3.	Comparativa de métricas Prophet y SARIMAX.....	48
6.4.	Análisis de tendencia futura.....	49
6.5.	Extrapolación de la predicción al precio de venta al público del vehículo eléctrico 50	
7.	Implicaciones Éticas e Impacto Social.....	53
7.1.	Descarbonización del Parque Automovilístico	53
7.2.	Concienciación sobre la Escasez de Materias Primas	53
7.3.	Equidad y Accesibilidad	54
7.4.	Educación y Concienciación Pública	54
8.	Conclusiones	55
9.	Otros Méritos del Proyecto	57
10.	Bibliografía	59

Anexo A: Exploratory Data Analysis (EDA)	65
Anexo B: Muestra de las variables.....	69
Anexo C: Publicaciones en redes sociales.....	71
Anexo D: Publicaciones en redes sociales	73

Índice de Tablas

Tabla 1. Resultados de las pruebas ADF y PP para comprobar la estacionariedad de la serie temporal. Fuente: elaboración propia. 39

Tabla 2. Comparación de métricas de evaluación para los modelos Prophet y SARIMAX. Fuente: elaboración propia. 48

Tabla 3. Muestra de las variables utilizadas. Fuente: REFINITIV EIKON. 69

Índice de Figuras

<i>Ilustración 1. Evolución del stock mundial de vehículos eléctricos proyectada hasta 2050. Fuente: (Xu, 2020).</i>	4
<i>Ilustración 2. Demanda y demanda acumulada de Litio en 2020-2050, sin reciclaje y con reciclaje hidrometalúrgico. Fuente: (Xu, 2020).</i>	5
<i>Ilustración 3. Porcentaje de recursos y producción del Litio por países. Fuente: (Servicio Geológico de EE. UU., 2022). Nota: EE. UU. retuvo sus datos.</i>	5
<i>Ilustración 4. Proyección de reducción de emisiones de CO2 para nuevos turismos y furgonetas, comparado con los objetivos de 2021. Fuente: (Consejo Europeo, 2023).</i>	9
<i>Ilustración 5. Ejemplo de regresión lineal. Fuente: (Hyndman & Athanasopoulos, 2021).</i>	12
<i>Ilustración 6. Esquema de funcionamiento de la técnica de validación cruzada. En azul, los subconjuntos de entrenamiento; en naranja, los de validación. Fuente: elaboración propia.</i>	14
<i>Ilustración 7. Flujograma del proceso técnico. Parte I. Fuente: elaboración propia.</i>	28
<i>Ilustración 8. Flujograma del proceso técnico. Parte II. Fuente: elaboración propia.</i>	29
<i>Ilustración 9. Diagrama de Gantt inicial del proyecto. Fuente: elaboración propia.</i>	32
<i>Ilustración 10. Diagrama de Gantt final del proyecto. Fuente: elaboración propia.</i>	33
<i>Ilustración 11. Matriz de correlación entre las variables del conjunto de datos. Fuente: elaboración propia.</i>	35
<i>Ilustración 12. Matriz de correlación entre las variables del conjunto de datos y la variable PC1. Fuente: elaboración propia.</i>	36
<i>Ilustración 13. Representación gráfica de la serie temporal. Fuente: elaboración propia.</i>	37
<i>Ilustración 14. Descomposición de la serie temporal original. Fuente: elaboración propia.</i>	38
<i>Ilustración 15. Descomposición estacional de la serie temporal con una diferenciación aplicada. Fuente: elaboración propia.</i>	40
<i>Ilustración 16. Autocorrelación de la serie temporal. Fuente: elaboración propia.</i>	40
<i>Ilustración 17. Autocorrelaciones de la serie temporal con una y con dos diferenciaciones aplicadas. Fuente: elaboración propia.</i>	41
<i>Ilustración 18. Autocorrelación parcial de la serie temporal con una diferenciación aplicada. Fuente: elaboración propia.</i>	41
<i>Ilustración 19. Resultados de la ejecución de la función "auto_arima" en la serie temporal. Fuente: elaboración propia.</i>	42
<i>Ilustración 20. Predicción de la serie original con el modelo SARIMAX (2, 1, 2). Fuente: elaboración propia.</i>	42
<i>Ilustración 21. Resultados de la ejecución de la función "auto_arima" en la serie temporal aumentada. Fuente: elaboración propia.</i>	43
<i>Ilustración 22. Residuos del modelo SARIMAX(0,1,2). Fuente: elaboración propia.</i>	44

<i>Ilustración 23. Autocorrelaciones de los residuos del modelo SARIMAX(0,1,2). Fuente: elaboración propia.</i>	<i>44</i>
<i>Ilustración 24. Gráfico de densidad para evaluar la normalidad de los residuos del modelo SARIMAX(0,1,2). Fuente: elaboración propia.</i>	<i>45</i>
<i>Ilustración 25. Histograma de los residuos del modelo SARIMAX(0,1,2) con la densidad estimada. Fuente: elaboración propia.</i>	<i>45</i>
<i>Ilustración 26. Relación de ajuste entre los valores observados y los valores ajustados por el modelo SARIMAX. Fuente: elaboración propia.</i>	<i>46</i>
<i>Ilustración 27. Predicción de la serie temporal diferenciada con el modelo Prophet. Fuente: elaboración propia.</i>	<i>47</i>
<i>Ilustración 28. Resultados de la predicción. En azul, los datos históricos; en naranja, los predichos. Fuente: elaboración propia.</i>	<i>48</i>
<i>Ilustración 29. Comparativa de métricas de evaluación. Fuente: elaboración propia.</i>	<i>49</i>
<i>Ilustración 30. Detalle de los valores predichos. Fuente: elaboración propia.</i>	<i>50</i>
<i>Ilustración 31. Histograma de las variables del conjunto de datos. Fuente: elaboración propia.</i>	<i>65</i>
<i>Ilustración 32. Diagrama de caja de las variables Close, Net, %Chg y High. Fuente: elaboración propia.</i>	<i>66</i>
<i>Ilustración 33. Diagrama de caja de las variables Volume, Turnover - USD y Flow. Fuente: elaboración propia.</i>	<i>66</i>
<i>Ilustración 34. Relaciones por pares del conjunto de datos. Fuente: elaboración propia.</i>	<i>67</i>
<i>Ilustración 35. Precios estimados de venta al público (antes de impuestos) para vehículos de pasajeros y furgonetas. Fuente: (BloombergNEF, 2021).....</i>	<i>71</i>
<i>Ilustración 36. Composición de las publicaciones realizadas en la red social LinkedIn. Fuente: elaboración propia.</i>	<i>73</i>

Lista de Acrónimos

Acrónimo	Significado
PVP	Precio de Venta al Público
EGD	European Green Deal
UE	Unión Europea
GEI	Gases de Efecto Invernadero
ETS	Emissions Trading System
PNIEC	Plan Nacional Integrado de Energía y Clima
LIB	Lithium-ion Batteries
BEV	Battery Electric Vehicle
PHEV	Plug-in Hybrid Electric Vehicle
STEP	Stated Policies scenario
SD	Sustainable Development scenario
EoL	End of Life
RNN	Recurrent Neural Network
LSTM	Long short-term memory
AR	Auto-Regression
MA	Moving-average
ARMA	AutoRegressive Moving Average
ARIMA	AutoRegressive Integrated Moving Average
SARIMAX	Seasonal AutoRegressive Integrated Moving Average with exogenous factors
RSME	Root Mean Square Error
MAPE	Mean Absolute Percentage Deviation
DF	Dickey-Fuller
ADF	Augmented Dickey-Fuller
PP	Phillips-Perron
MaaS	Mobility as a Service
BEV	Battery Electric Vehicle
ICE	Internal Combustion Engine

1. INTRODUCCIÓN

El mercado de los vehículos eléctricos puros, los vehículos híbridos enchufables, los vehículos híbridos o los vehículos microhíbridos está en auge; un auge posibilitado por los avances técnicos que facilitan la democratización de este tipo de vehículos y por las normativas y legislaciones que motivan su popularización.

A lo largo del presente documento se propone un proyecto de predicción del precio del Litio. Esta propuesta alberga una gran relevancia dado que, por medio de la aplicación de la tecnología, se consigue aportar valor en el estudio crítico del comportamiento de los precios del Litio, como uno de los factores fundamentales que establecen el precio final del vehículo eléctrico. Este hecho otorga un valor añadido por la contextualización y facilitación de la toma de decisiones informada.

1.1. DESCRIPCIÓN DEL PROBLEMA

Ante las grandes fluctuaciones del mercado actual, motivadas por los tiempos de inestabilidad en los que nos encontramos, resulta complicado saber cuál va a ser el escenario en el que entren en vigor las normativas en favor del clima y, en consecuencia, cuál va a ser la eficacia de estas medidas.

Este es el motivo por lo que adquiere una gran relevancia la posibilidad de predecir variables como la evolución del precio del Litio, un material que actualmente es clave en el desarrollo del mercado de los vehículos eléctricos y que sin duda tendrá un papel protagonista en el desarrollo de los acontecimientos futuros.

1.2. MOTIVACIÓN DEL TRABAJO

Gracias a la gran cantidad de información que se recopila constantemente en todo el mundo, lo que llamamos *Big Data*, y a la tecnología disponible actualmente, se tiene la capacidad de llevar a cabo predicciones cada vez más fiables que nos permiten conocer una realidad antes de que suceda.

Así es como, de la relevancia de las nuevas regulaciones en materia medioambiental y de la capacidad de realizar predicciones fiables, surge la motivación de este trabajo, en el que se pretende realizar una predicción ajustada del precio del Litio, dada su innegable relevancia en el mundo de los EVs.

1.3. ORGANIZACIÓN DE LA MEMORIA

El documento está organizado en 9 capítulos, cada uno de los cuales reúne diferentes secciones de propósito común. Estos capítulos, nombrados en orden de aparición, son los siguientes: Introducción, Investigación Previa, Objetivos, Plan de Desarrollo del Proyecto, Desarrollo de la Solución Técnica, Resultados, Implicaciones Éticas e Impacto Social, Conclusiones y Otros Méritos del Proyecto.

En el presente capítulo, el Capítulo 1, se ofrece una introducción del tema del proyecto, situando al lector en la temática de este. Además, se expone la descripción del problema planteado y la motivación que ha llevado a realizar el trabajo. Igualmente se aporta la presente organización de la memoria, con el fin de facilitar la comprensión del documento.

En el Capítulo 2, se realiza una descripción de la investigación previa necesaria para producir este documento, haciendo un recorrido a través de lo que se puede encontrar hoy en día en relación, tanto con el campo del *Machine Learning* y del *Big Data* (principalmente desde el siglo XX hasta la actualidad), como de las tecnologías presentes en las baterías actualmente, enfocándose en aquellas que el Litio es la principal materia prima. Asimismo, se tratan los marcos legales y técnicos necesarios para comprender los temas que se abordan. Para cerrar el capítulo, se tratan los criterios de desempeño empleados en la parte técnica del proyecto.

En el Capítulo 3, se redactan tanto el objetivo general como los objetivos específicos del proyecto, necesarios para mantener un enfoque a la hora de desarrollar el trabajo.

En el Capítulo 4 se expone el plan de desarrollo del proyecto, que alberga la metodología empleada, las tecnologías usadas, el plan de trabajo que se ha seguido, los recursos que se han necesitado para su desarrollo y los condicionantes y limitaciones del proyecto.

En el Capítulo 5 se propone el desarrollo de la solución técnica empleada, en la que se llevará a la práctica lo definido en la metodología propuesta en el capítulo anterior.

En el Capítulo 6 se exponen los resultados obtenidos del desarrollo técnico.

El Capítulo 7 menciona las implicaciones éticas y el impacto social del proyecto.

En el Capítulo 8 se establecen las conclusiones a las que se llegan tras la realización del proyecto.

Finalmente, en el Capítulo 9 se hace referencia a otros méritos del proyecto.

2. INVESTIGACIÓN PREVIA

2.1. ESTADO DEL ARTE

La predicción de series temporales es un campo derivado de la estadística y las matemáticas que se ha ido desarrollando desde mediados del siglo pasado. Este campo tiene como objetivo predecir los valores futuros de una determinada serie temporal basándose en los valores pasados.

El *Machine Learning*¹ es una rama de la inteligencia artificial que tiene como propósito capacitar a la propia máquina para la toma de decisiones propias basándose en la aplicación de algoritmos y modelos estadísticos sobre la información que se le ha proporcionado. Esta información se le proporciona a la máquina en forma de conjuntos de datos (Flach, 2012). Durante los primeros años de desarrollo de este campo, se empleaban modelos de promedio móvil (MA) y modelos auto regresivos (AR). Sin embargo, pronto surgieron nuevos modelos más precisos que combinaban más de una técnica como es el caso del modelo ARMA surgido en la década de 1970 que adoptaba los modelos AR y MA, y el popular modelo ARIMA, de características similares (Box & Jenkins, 1970). También se desarrollan modelos de suavizado exponencial (ES), Utilizados especialmente para la predicción de series temporales con patrones de crecimiento o decrecimiento exponencial. A continuación del surgimiento de estos modelos, se desarrollaron los modelos de espacio de estados, cuya principal novedad es que permiten las series temporales no estacionarias y tener en consideración las incertidumbres asociadas con la predicción. Desde ese momento hasta nuestros días han ido surgiendo nuevos modelos cada vez más complejos y precisos. Uno de los modelos más populares utilizados en la actualidad es Prophet, desarrollado por Facebook en 2017 (Taylor & Letham, 2017).

Los modelos más precisos que encontramos en la actualidad son los basados en redes neuronales recurrentes (RNN) y los basados en redes neuronales convolucionales (CNN). En 1997 surge una variante de estos modelos: el modelo propuesto por Hochreiter y Schmidhuber (Hochreiter & Schmidhuber, 1997). Esta nueva variante, Redes Neuronales Recurrentes con Memoria a Corto y Largo Plazo, es conocida por sus siglas en inglés LSTM, y permite procesar y predecir series temporales con dependencias a largo plazo, mediante

¹ Término acuñado por Arthur Samuel, pionero de la inteligencia artificial, en la década de 1950. Se puede traducir como “aprendizaje automático”.

la incorporación de un mecanismo de memoria que permite recordar la información más relevante, al mismo tiempo que se descarta la información menos relevante en el tiempo.

Son numerosas las aplicaciones prácticas que se le han dado a este campo. Por ejemplo, se utilizan para pronosticar el precio de las acciones, la demanda de energía, el tráfico de redes y la carga de servidores entre otras muchas aplicaciones (Hyndman & Athanasopoulos, 2021).

La predicción de valores de mercado, como es el caso del Litio, permite adelantar cuál será la evolución de precios de otras tecnologías que dependen de este material, como las baterías de los vehículos eléctricos. Estas baterías de iones de Litio (LIB) contienen Litio (Li), Cobalto (Co) y Níquel (Ni) en el cátodo, Grafito en el ánodo, así como Aluminio y Cobre en otros componentes de celdas y paquetes. Tal y como se asegura en (Hao & Sarkis, 2016) y en (Deng, 2020), la gran demanda global de este tipo de vehículos, consecuencia del progreso tecnológico reciente y las ayudas gubernamentales, está aumentando el consumo de Litio (Ilustración 1). La principal consecuencia de este cambio de tendencia es el cambio de roles entre la gasolina y el Litio: la demanda de gasolina comenzará a caer, a la vez que la industria del Litio comenzará a desempeñar un papel principal. A su vez, se estima que la demanda de esta materia prima aumentará entre 18 y 20 veces, a partir de 2020 hasta 2050 (Ilustración 2) (Xu, 2020). A pesar de que la oferta de Litio en la Tierra es limitada, la cantidad de este material conocida en la corteza terrestre es suficiente para satisfacer la creciente demanda de baterías de iones de Litio en el corto y medio plazo (Weil, 2018). Además, la existencia de grandes reservas de Litio aún sin explotar, como las presentes en Bolivia, o el aumento en la eficiencia del proceso de reciclaje del Litio presente en las baterías, supondrá una reducción de la presión sobre la disponibilidad del Litio (Ziemann, B. Müller, Liselotte, & Weil, 2018). Todo ello deberá estar apoyado con la ampliación requerida de las cadenas de suministro para satisfacer la demanda esperada (Olivetti, 2017).




Ilustración 1. Evolución del stock mundial de vehículos eléctricos proyectada hasta 2050². Fuente: (Xu, 2020).

² El escenario STEP y el escenario SD son dos escenarios de la Agencia Internacional de la Energía (AIE) contemplados hasta 2030: el escenario de Políticas Declaradas (STEP), que incorpora las políticas




Ilustración 2. Demanda y demanda acumulada de Litio en 2020-2050, sin reciclaje y con reciclaje hidrometalúrgico³. Fuente: (Xu, 2020).

Tras haber realizado un recorrido por diversos factores que condicionan la evolución del precio del Litio (la oferta y la demanda, las tecnologías disponibles o el reciclaje de baterías usadas), no se puede obviar un factor que recientemente ha ganado en importancia: el factor geopolítico. Tras la invasión de Rusia a Ucrania, el enfrentamiento entre los países de economía capitalista y los países de economía comunista se ha hecho más evidente. Como consecuencia de las sanciones impuestas por la ONU, el comercio entre estos países se ha dificultado, encareciéndose los productos. En el ámbito del Litio, China dispone del 5,8 % de las reservas mundiales de esta materia prima y la explotación que hace de ella supone un 13 % del total (Ilustración 3), ocupando el tercer puesto a escala mundial de mayor aprovechamiento.




Ilustración 3. Porcentaje de recursos y producción del Litio por países. Fuente: (Servicio Geológico de EE. UU., 2022). Nota: EE. UU. retuvo sus datos.

gubernamentales existentes, y el escenario de Desarrollo Sostenible (DS), que es compatible con los objetivos climáticos pactados en el Acuerdo de París.

³ El procesamiento hidrometalúrgico implica la lixiviación con ácido y la posterior recuperación de los materiales de la batería, por ejemplo, a través de la extracción con solventes y la precipitación.

Por otra parte, en el reciente XIV Plan Quinquenal Chino (Asian Development Bank, 2021), publicado para el periodo de 2021-2025, uno de los objetivos principales establecidos es el de buscar la neutralidad de carbono. Para ello, la proporción de combustibles no fósiles en el consumo de energía primaria se fija en un 20 % desde el 15 % del plan anterior.

2.2. MARCO LEGAL

2.2.1. Legislación europea

El Pacto Verde Europeo

El Pacto Verde Europeo, también conocido por sus siglas en inglés EGD (European Green Deal), es un conjunto de políticas y estrategias adoptadas por la Unión Europea (UE) con el objetivo último de lograr la neutralidad climática para el año 2050. El EGD establece una hoja de ruta para la transformación de la economía europea de forma sostenible, afrontando los desafíos del cambio climático, la protección del medio ambiente y la promoción de la sostenibilidad.

El Pacto Verde Europeo sienta sus bases en el Acuerdo de París⁴ y, como se ha expuesto anteriormente, tiene como objetivo principal abordar la crisis climática y reducir las emisiones de gases de efecto invernadero (GEI). Además de abordar esta mitigación del cambio climático, el EGD también busca impulsar la transición hacia una economía circular, restaurar la biodiversidad, promover la eficiencia energética y garantizar una transición justa para todos los sectores y regiones afectados (Consejo Europeo, 2022).

Además del objetivo principal del Pacto Verde Europeo, se establecen una serie de iniciativas que buscan lograr una transición hacia una economía sostenible y neutral en carbono. A continuación, se mencionan todos los puntos que comprende el EGD, prestando especial atención a aquellos más significativos para este proyecto:

- **Objetivo 55:** El objetivo principal de este paquete es legislar las propuestas recogidas en el EGD. En él se recogen propuestas de revisión de legislaciones relativas a los objetivos climáticos de la propia Unión Europea. Debido a su importancia para este proyecto, este conjunto de propuestas se analizará en apartados posteriores.
- **Legislación Europea sobre el Clima:** El objetivo principal de esta iniciativa es el de convertir la propuesta de alcanzar la neutralidad climática en 2050 en una obligación jurídica de la Unión Europea. Además, la propia Unión Europea, así como sus estados miembros, adquieren el compromiso de conseguir una reducción de las

⁴ Naciones Unidas, *Acuerdo de París*, 2015. “El Acuerdo es un tratado internacional legalmente vinculante. Entró en vigor el 4 de noviembre de 2016. En la actualidad, 194 partes (193 países más la Unión Europea) han firmado el Acuerdo de París. El Acuerdo incluye compromisos de todos los países para reducir sus emisiones y colaborar juntos a fin de adaptarse a los impactos del cambio climático.” (Naciones Unidas, s.f.)

emisiones netas de carbono en al menos un 55 % para 2030, con respecto a los valores de 1990.

- Estrategia de adaptación al cambio climático de la UE.
- Estrategia de la UE sobre la Biodiversidad de aquí a 2030.
- Estrategia «De la Granja a la Mesa».
- Estrategia Industrial Europea.
- Plan de Acción para la Economía Circular.
- Pilas y baterías y sus residuos: Se propone realizar una revisión de la normativa vigente sobre pilas y baterías. Además, se propone adoptar nuevos requisitos de obligatorio cumplimiento para todas las baterías que circulen en el mercado de la Unión Europea. El principal objetivo de esta iniciativa es el de mantener un control exhaustivo de la vida de las baterías, desde su fabricación hasta su reciclaje y segunda vida.
- Transición justa.
- Energía limpia, asequible y segura.
- Estrategia de la UE para la sostenibilidad de las sustancias químicas.
- Estrategia forestal e importaciones libres de deforestación.

Reglamento (UE) 2023/851

Se trata de un documento que da continuidad a El Pacto Verde Europeo. Surge de la proposición de aumentar la ambición de la Unión Europea, en términos de intensificar la ambición climática para 2030 (mismo nombre que la Comisión creada para tales propósitos), con el objetivo final de reducir en al menos un 55 % las emisiones netas de gases de efecto invernadero con respecto a 1990, de forma responsable (Reglamento (UE) 2019/631, 2019).

Este Reglamento, y por extensión la propuesta de modificación se encuentra en consonancia con los objetivos establecidos en el Acuerdo de París.

El Reglamento (UE) 2023/851 modifica el Reglamento (UE) 2019/631 en lo referente a las emisiones de CO₂ de los turismos nuevos y los vehículos comerciales ligeros nuevos. Las modificaciones que repercuten en mayor medida en el presente proyecto son las siguientes:

- Artículo 1.
 - Apartado 5.

“a) para las emisiones medias del parque de turismos nuevos, un objetivo a escala del parque de la Unión igual a una reducción del 55 % del objetivo en 2021 [...];

b) para las emisiones medias del parque de vehículos comerciales ligeros nuevos, un objetivo a escala del parque de la Unión igual a una reducción del 50 % del objetivo en 2021 [...].”

(Reglamento (UE) 2023/851, 2023).

- Apartado 5 bis.

“a) para las emisiones medias del parque de turismos nuevos, un objetivo a escala del parque de la Unión igual a una reducción del 100 % del objetivo en 2021 [...];

b) para las emisiones medias del parque de vehículos comerciales ligeros nuevos, un objetivo a escala del parque de la Unión igual a una reducción del 100 % del objetivo en 2021 [...].”

(Reglamento (UE) 2023/851, 2023).

- Apartado 6.

“Del 1 de enero de 2025 al 31 de diciembre de 2029, se aplicará un índice de referencia para los vehículos de emisión cero y de baja emisión igual a una cuota del 15 % del parque de turismos nuevos y del parque de vehículos comerciales ligeros nuevos [...].”

(Reglamento (UE) 2023/851, 2023).

Objetivo 55

El paquete de medidas englobado bajo el nombre de Objetivo 55 (también referido como *Fit for 55*) es un conjunto de propuestas que pretenden actualizar la legislación para que esté acorde con los objetivos climáticos acordados por el Consejo y el Parlamento Europeo. El objetivo principal de este conjunto de medidas es reducir las emisiones de gases de efecto invernadero (GEI) en al menos un 55 % para el año 2030, en comparación con los niveles de 1990.

Como se ha mencionado anteriormente, este Objetivo 55 se enmarca en el Pacto Verde Europeo, que a su vez deriva del Acuerdo de París. Las propuestas que se incluyen son las siguientes (Consejo Europeo, 2023):

- Sistema de comercio de derechos de emisión (ETS) de la UE: Se ampliará el alcance del ETS de la UE, que es el sistema de comercio de emisiones de la UE, para incluir sectores adicionales como la aviación y el transporte marítimo. Esto incentivará una reducción de las emisiones en estos sectores.
- Fondo de clima social.
- Mecanismo de ajuste de carbono en las fronteras: Se explorarán opciones para establecer un mecanismo de ajuste de carbono en las fronteras de la UE, lo que implicaría aplicar impuestos sobre el carbono a ciertos productos importados. Esto

tiene como objetivo evitar fugas de carbono y promover la equidad en la competencia.

- Objetivos de reducción de emisiones de los estados miembros.
- Emisiones y absorciones por uso de la tierra, cambio de uso de la tierra y silvicultura.
- Normas de emisión de CO₂ para turismos y furgonetas: Los turismos y furgonetas representan aproximadamente el 15 % de las emisiones totales de dióxido de carbono de la Unión Europea. Como parte del paquete del Objetivo 55, se incluye la introducción de objetivos de reducción progresiva de emisiones en toda la UE para turismos y furgonetas, con vigencia a partir de 2030, y llegado a una reducción del 100 % para el año 2035.




Ilustración 4. Proyección de reducción de emisiones de CO₂ para nuevos turismos y furgonetas, comparado con los objetivos de 2021. Fuente: (Consejo Europeo, 2023).

- Reducción de las emisiones de metano en el sector energético
- Combustibles de aviación sostenibles.
- Combustibles más ecológicos en el transporte marítimo.
- Infraestructura de combustibles alternativos.
- Energía renovable.
- Eficiencia energética: Se implementarán medidas para mejorar la eficiencia energética en los edificios, la industria y el transporte. Esto incluirá estándares más estrictos, incentivos para la renovación de edificios y la promoción de tecnologías eficientes.
- Paquete de mercado de hidrógeno y gas descarbonizado.
- Fiscalidad de la energía.

2.2.2. Legislación española

Ley de cambio climático y transición energética.

Esta ley tiene como objetivo garantizar el cumplimiento de los compromisos del Acuerdo de París y establece medidas para lograr la neutralidad de carbono en España antes de 2050 y promover un sistema energético eficiente y renovable (BOE, 2021).

Entre los puntos clave de la ley se encuentran los siguientes objetivos para 2030: reducir al menos un 23 % las emisiones de gases de efecto invernadero en comparación con 1990, alcanzar al menos un 42 % de consumo de energías renovables, asegurar que al menos un 74 % de la generación en el sistema eléctrico provenga de fuentes renovables y disminuir en al menos un 39,5 % el consumo de energía primaria en línea con las normas comunitarias (Deloitte, 2021).

La ley establece herramientas de acción climática, como el Plan Nacional Integrado de Energía y Clima (PNIEC) para integrar objetivos y políticas en todos los sectores económicos, la Estrategia de Descarbonización a 2050 para reducir emisiones en el largo plazo y la promoción de la digitalización de la economía para apoyar la descarbonización.

En cuanto a las energías renovables, se prioriza el apoyo a tecnologías renovables en las concesiones de dominio público hidráulico y se fomenta el uso de gases renovables como biogás, biometano e hidrógeno. Además, se introduce un nuevo marco retributivo para la producción renovable basado en la prudencia financiera.

La ley también aborda la movilidad sostenible, estableciendo el objetivo de eliminar las emisiones directas de CO₂ en los turismos y vehículos comerciales ligeros para 2050. Se promueve la instalación progresiva de infraestructura de recarga eléctrica en estaciones de servicio. Además, las ciudades con una población mayor a 50.000 habitantes deberán establecer Zonas de Bajas Emisiones en 2023, así como fomentar soluciones de movilidad menos contaminantes (Ferrovial, 2021).

Para avanzar hacia una transición justa, se establecen estrategias y convenios de transición justa para garantizar la igualdad y solidaridad entre territorios y personas afectadas por el cambio climático. También se regula el cese de producción de carbón y se promueve la educación y capacitación sobre cambio climático.

La ley destina recursos financieros a la lucha contra el cambio climático y establece la aplicación de porcentajes de los Presupuestos Generales del Estado y los ingresos de subastas de derechos de emisión a estos objetivos.

En términos de gobernanza climática, se crea un Comité de Personas Expertas de Cambio Climático y Transición Energética y se promueve la participación pública y el acceso a información relevante a través de una página web.

2.3. MARCO TÉCNICO

2.3.1. Series temporales

Series temporales

El concepto más básico para la realización de predicciones son las series temporales. Estas son un conjunto de observaciones almacenadas a lo largo del tiempo, normalmente con una frecuencia periódica (diariamente, semanalmente o con cualquier otra frecuencia).

Componentes de las series temporales

Las series temporales se identifican por una serie de componentes:

- Componente de tendencia. Se trata de aquellas variaciones que son a largo plazo. Se trata de una variación tenue a lo largo del tiempo.
- Componente de estacionalidad. No es común a todas las series temporales. Las series que presentan esta característica muestran cierta periodicidad.
- Componente aleatoria. Es lo que se denomina “ruido” de una serie temporal. No tienen periodicidad ni tendencia apreciable.

Estos tres componentes de una serie temporal se pueden expresar por medio de la siguiente expresión matemática:

$$X_t = T_t + E_t + I_t \quad (2.1)$$

donde T_t es la componente de tendencia, E_t es la componente de estacionalidad e I_t es la componente aleatoria.

Clasificación de las series temporales

Podemos establecer una clasificación de las series temporales:

- Estacionarias. En este tipo de series temporales, los datos oscilan en torno a una media, varianza y covarianza constantes. Además, su tendencia se mantiene constante a lo largo del tiempo (Rhif, Ben Abbes, Riadh Farah, Martínez, & Sang, 2019).
- No estacionarias. En este tipo de series temporales, al contrario que en las series estacionarias, los datos no oscilan en torno a una media constante, si no que se sitúan en torno a una tendencia creciente o decreciente.

2.3.2. Modelos matemáticos

Regresión lineal

Para comprender los modelos de regresión, lo mejor es empezar por el más sencillo y conocido de todos ellos: la regresión lineal. Este modelo de regresión permite una relación lineal entre la variable de pronóstico y y una o varias variables predictoras x :

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t \quad (2.2)$$

donde y es la variable a pronosticar y $x_1, x_2, \dots, x_k$ son las k variables predictoras. El término ε_t es el error aleatorio. El término *error* no implica un error, sino una desviación del modelo de línea recta subyacente.

Podemos escribir esto en forma matricial, donde todos los valores de la variable de pronóstico se dan en una sola ecuación.

Siendo $\mathbf{y} = (y_1, \dots, y_T)'$, $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_T)'$, $\boldsymbol{\beta} = (\beta_0, \dots, \beta_k)'$,

$$\mathbf{X} = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} & \cdots & x_{k,1} \\ 1 & x_{1,2} & x_{2,2} & \cdots & x_{k,2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,T} & x_{2,T} & \cdots & x_{k,T} \end{bmatrix} \quad (2.3)$$

Por lo que $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$




Ilustración 5. Ejemplo de regresión lineal. Fuente: (Hyndman & Athanasopoulos, 2021).

Regresiones no lineales

Aunque la mayoría de las veces una regresión lineal pueda ser adecuada para nuestros propósitos, a veces será necesario recurrir a regresiones no lineales que se ajusten. La forma más sencilla de transformar una relación lineal en una no lineal es transformar la variable predictora x y/o la variable de pronóstico y . La transformación más utilizada es el logaritmo natural:

$$\log y = \beta_0 + \beta_1 x_{1,t} + \varepsilon_t \quad (2.4)$$

Hay casos en los que la simple transformación de los datos no será suficiente y puede ser necesaria una especificación más general. Entonces el modelo que usamos es:

$$y = f(x) + \varepsilon_t, \quad (2.5)$$

donde $f(x)$ es una función no lineal.

Modelos aditivos

Este tipo de modelo fue propuesto en 1981 por Jerome H. Friedman y Werner Stuetzle. Destaca su flexibilidad frente a los modelos lineales estándar (Friedman & Stuetzle, 1981).

Se puede describir matemáticamente de la siguiente forma:

$$Y = \beta_0 + \sum_{j=1}^p f_j(X_j) + \varepsilon \quad (2.6)$$

donde Y es el conjunto de datos y X es el conjunto que representa los predictores. A su vez, $E[\varepsilon] = 0$, $Var(\varepsilon) = \sigma^2$ y $E[f_j(X_j)] = 0$. Las funciones $f_j(X_j)$ son funciones ajustadas a partir de los datos.

Teorema de Bayes

Este teorema tiene una gran importancia a la hora de implementar un análisis sobre una serie temporal. En él, se establece la relación de que existe entre la probabilidad de A dado B, con la probabilidad de B dado A; lo que se traduce en que la probabilidad de un evento dado se puede calcular a partir de la probabilidad previa del evento y de la evidencia observada (Bayes, 1763).

La siguiente fórmula matemática expresa lo anteriormente expuesto:

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{P(B)} \quad (2.7)$$

donde $P(B|A_i)$ es la probabilidad de que suceda B dado el evento A,

$P(A_i|B)$ es la probabilidad de que suceda A dado el evento B,

$P(A)$ es la probabilidad de que suceda el evento A y

$P(B)$ es la probabilidad de que suceda el evento B.

Si hacemos un análisis de $P(B)$, podemos determinar que:

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{P(A_i)P(B|A_i) + P(-A_i)P(B|-A_i)} \quad (2.8)$$

Validación cruzada

La validación cruzada es un método que se utiliza a la hora de realizar un análisis de carácter estadístico y tiene como objetivo certificar que no existe una conexión entre los datos utilizados para el entrenamiento del modelo y los datos utilizados para la validación de este. Es comúnmente usado en los casos en los que no se dispone de un conjunto de datos suficientemente amplio como para proporcionar un ajuste suficientemente preciso (Devijver & Kittler, 1982).

La validación cruzada implica dividir el conjunto de datos en subconjuntos, habitualmente llamados *folds*, que se utilizan para entrenar y validar el modelo en sucesivas iteraciones. El proceso tiene tantas iteraciones como *folds* se hayan definido y en cada iteración se toma un *fold* como conjunto de datos de validación y los restantes se toman como datos de entrenamiento. En la siguiente iteración, el subconjunto de datos de validación pasa a ser otro *fold* y, consecuentemente, el subconjunto de datos de entrenamiento pasa a ser los *folds* restantes. Para cada interacción se calculan las métricas de evaluación deseadas y al final del proceso se promedian los resultados de todas las interacciones que han tenido lugar (Refaeilzadeh, Tang, & Lui, 2008).

1ª iteración		...					
2ª iteración		...					
3ª iteración		...					
4ª iteración		...					
	...	...	...	...	...	...	...
k iteración		...					

Ilustración 6. Esquema de funcionamiento de la técnica de validación cruzada. En azul, los subconjuntos de entrenamiento; en naranja, los de validación. Fuente: elaboración propia.

Cadenas de Markov

Las cadenas de Markov son un modelo matemático utilizado para representar sistemas estocásticos que evolucionan en el tiempo.

Formalmente, una cadena de Markov se define como una secuencia de variables aleatorias que toman valores en un conjunto finito o infinito de estados. La evolución del sistema se rige por una matriz de probabilidad de transición, que establece la probabilidad de transición de un estado a otro en un solo paso. Esta matriz debe ser estocástica, es decir, cada fila debe sumar 1 y cada entrada debe ser no negativa.

La propiedad fundamental de una cadena de Markov es la propiedad de Markov, que establece que la probabilidad de transición de un estado a otro solo depende del estado actual y no de los estados pasados. Esta propiedad permite simplificar el modelo y reducir la cantidad de información necesaria para representar el sistema (Meyn & Tweedie, 1993).

Para exponerlo en términos matemáticos, podemos decir que, dado el estado actual X_n , y siendo conocidos los estados previos $X_1, X_2, \dots, X_{n-1}$, para cualquier sucesión de estados $x_1, x_2, \dots, x_{n+1} \in S$, podemos establecer que:

$$\begin{aligned} P(X_{n+1} = x_{n+1} \mid X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \\ = P(X_{n+1} = x_{n+1} \mid X_n = x_n) \end{aligned} \quad (2.9)$$

siendo S el espacio de estados discreto.

Siendo i y j dos estados de la cadena de Markov, podemos expresar la probabilidad de ir al estado i en el tiempo n , y al estado j en el tiempo $n + 1$ de la siguiente manera:

$$p_{ij}(n, n + 1) = P(X_{n+1} = j \mid X_n = i) = P(X_1 = j \mid X_0 = i) \quad (2.10)$$

Una vez tenemos las probabilidades de transición de un paso, podemos obtener la matriz de probabilidades de transición de forma inmediata:

$$P = \begin{pmatrix} p_{11} & \cdots & p_{1k} \\ p_{21} & \cdots & p_{2k} \\ \vdots & \ddots & \vdots \\ p_{k1} & \cdots & p_{kk} \end{pmatrix} \quad (2.11)$$

de forma que $p_{ij} \geq 0$ y $\sum_{j \in S} p_{ij} = 1$.

(Cox & Miller, 1970).

Modelo ARIMA

El modelo ARIMA (*Autoregressive Integrated Moving Average*) es un modelo autorregresivo sistematizado por Box y Jenkins en 1970, integrado de medias móviles. Es un modelo dinámico de predicciones de series temporales, puesto que los valores predichos dependen de los valores anteriores (Box & Jenkins, 1970).

Para ejemplificar el acercamiento realizado por Box y Jenkins, tomaremos una serie temporal no estacionaria $\{X\}$. Podremos explicar los diferentes valores que va tomando la serie temporal basándonos en una combinación de los valores pasados y un ruido. Los autores proponen que existe un valor entero d para el que la ecuación:

$$w_t = (1 - B)^d X_t \quad (2.12)$$

es estacionaria, donde $B^j x_t = x_{t-j}$. De esta forma, podemos expresar el valor de la serie temporal en cada instante t por medio de la siguiente ecuación:

$$w_t = \frac{\theta_q(B)^q}{\varphi_p(B)^p} a_t \quad (2.13)$$

donde a_t es el ruido blanco y $\theta_q(B)^q = (1 - \theta_1 B \dots, \theta_q B^q)$, y $\varphi_p(B)^p = (1 - \varphi_1 B \dots, \varphi_p B^p)$.

Finalmente, si combinamos ambas ecuaciones obtenemos la ecuación general del modelo Box-Jenkins, aplicable a series temporales no estacionarias:

$$\varphi_p(B)^p (1 - B)^d X_t = \theta_0 + \theta_q(B)^q a_t \quad (2.14)$$

donde θ_0 es una constante diferente a cero.⁵

En una notación de Box-Jenkins, esta última ecuación representa un modelo ARIMA de orden (p, d, q) , donde p es el grado del proceso autorregresivo, d es el grado de diferenciación, y q es el grado del proceso de medias móviles (Young, 1977).

Para ajustar estos valores, se puede seguir el proceso que se propone a continuación (Liu L. M., Hudak, Box, Muller, & Tiao, 1992):

⁵ La constante θ_0 puede tomar un valor distinto de cero, por ejemplo, en casos que requieren "diferenciación". Esto introduce un polinomio de grado d , que es, por naturaleza, determinista, en la función de pronóstico generada. Véase (Box & Jenkins, 1970), págs. 91-94 y 194-195.

1. Identificación del modelo. En este paso, la serie temporal se analiza desde un punto de vista estadístico, comprobando la estacionariedad (ver apartado 2.3.1) y la autocorrelación de los valores.
2. Estimación. En este paso, los parámetros del modelo se estiman basándose en la información disponible. Para decidir cuales es el conjunto de parámetros que mejor se ajusta al modelo, se tomará el Akaike Information Criterion (AIC), de forma que se busca encontrar el AIC más bajo (Akaike, 1974).
3. Comprobación del diagnóstico. El modelo que se ha estimado debe ser examinado con el fin de comprobar si es adecuado para predecir la serie temporal. Los residuos del modelo deben de estar no correlacionados. Se tomarán las funciones de Autocorrelación (ACF) y de Autocorrelación Parcial (PACF) para comprobar la autocorrelación entre los residuos.

Si los parámetros que se han definido para ajustar el modelo no son los adecuados, y la predicción de la serie temporal es fallida, se deberán repetir os tres pasos anteriormente descritos hasta obtener un ajuste de parámetros capaces de realizar la predicción requerida.

Modelo SARIMAX

El modelo SARIMAX (*Seasonal Auto Regressive Integrated Moving Average with Exogenous factors*), $(p, d, q)(P, D, Q)_s$, es una extensión del modelo ARIMA que es capaz de tomar en consideración una o varias series temporales exógenas, así como variables también exógenas (Liu L., Hudak, Box, Muller, & Tiao, 1997). Se describe por medio de la siguiente ecuación:

$$\phi_p(B)\Phi_p(B^s)(1-B)^d(1-B^s)^D Y_t = c + X_t\beta + \theta_q(B)\Theta_q(B^s)\varepsilon_t \quad (2.15)$$

donde Y_t es el valor dependiente de la serie temporal en el instante t ; ε_t es el residuo en ese instante de tiempo; B es el operador de retorno ($BY_t = Y_{t-1}$); (p,q,d) son los parámetros no estacionarios de autorregresión, diferenciación y medias móviles, respectivamente; (P, D, Q) son los parámetros estacionarios de autorregresión, diferenciación y medias móviles, respectivamente; ϕ y θ son los coeficientes de autorregresión y de medias móviles, respectivamente; Φ y Θ son los coeficientes estacionarios de autorregresión y de medias móviles, respectivamente; β hace referencia a los parámetros exógenos de la serie temporal X_t ; y s es la longitud del periodo estacionario.

Prophet

Según la propia página de esta herramienta, se define como:

“[...] a procedure for forecasting time series data based on an additive model where non-linear trends are fit with yearly, weekly, and daily seasonality, plus holiday effects. It works best with time series that have strong seasonal

effects and several seasons of historical data. Prophet is robust to missing data and shifts in the trend, and typically handles outliers well."

(Facebook Open Source, s.f.)

Prophet se basa principalmente en dos modelos matemáticos: el modelo aditivo y el modelo de regresión. Además de estos dos modelos principales, el algoritmo se basa en la metodología bayesiana para realizar las estimaciones de los parámetros y para la selección automática de modelos.

El algoritmo que implementa Prophet descompone la serie temporal en tres elementos: tendencia, estacionalidad y vacaciones, dando lugar a la siguiente ecuación:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (2.16)$$

donde $g(t)$ es la tendencia que modela los cambios no periódicos de la serie, $s(t)$ atiende a la periodicidad de los cambios, $h(t)$ hace referencia a las vacaciones que tienen repercusión en la serie temporal y ϵ representa el error.

A su vez, la tendencia se calcula por medio de la siguiente expresión:

$$g(t) = \frac{C}{1 + \exp(-k(t - m))} \quad (2.17)$$

donde C es la capacidad de carga, k es la ratio de crecimiento, y m es un valor de offset.

La estacionalidad se calcula por medio de transformadas de Fourier:

$$s(t) = \sum_{n=1}^N \left(a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right) \quad (2.18)$$

donde P es el periodo y el valor de $(a_n + b_n)$ se estima por medio de la distribución $N(0, \sigma^2)$, cuyos parámetros se concretan por medio de procesos de ajuste de modelos, como los que se verán más adelante, en la sección 5.

Para calcular el del impacto de las vacaciones sobre la serie temporal se alimenta al algoritmo con las fechas exactas de cada festividad pasada y futura (Taylor & Letham, 2017).

La justificación del uso de esta herramienta, en detrimento de otras que puedan obtener similares resultados, reside en que Prophet 1) es preciso y rápido, 2) es completamente automático, 3) realiza pronósticos ajustables, 4) está disponible en R o Python, 5) maneja bien las variaciones estacionales, 6) es robusto frente a valores atípicos y 7) es resistente a los datos faltantes. A continuación, se detallan los anteriores puntos:

- 1) Preciso y rápido. Debido a estas características, es usado en muchas aplicaciones en Facebook para producir pronósticos fidedignos para la planificación y el establecimiento de objetivos.
- 2) Completamente automático. Se obtienen pronósticos razonables sobre datos desordenados sin esfuerzo manual.
- 3) Pronósticos ajustables. La herramienta incluye muchas posibilidades para que los usuarios modifiquen y ajusten las previsiones. Podemos usar parámetros interpretables por humanos para mejorar el pronóstico agregando nuestro conocimiento del dominio.
- 4) Disponible en R o Python. En este caso, desarrollaremos nuestro trabajo en un entorno de Python.
- 5) Maneja bien las variaciones estacionales. Prophet se adapta a la estacionalidad con múltiples períodos.
- 6) Robusto frente a valores atípicos. Por defecto, maneja los valores atípicos eliminándolos.
- 7) Resistente a los datos faltantes: Se pueden adoptar diferentes estrategias para manejar valores faltantes, como eliminar esa columna de valores o prolongar el anterior valor válido.

2.4. DESCRIPCIÓN DEL CONJUNTO DE DATOS EN EL CASO DE ESTUDIO

El conjunto de datos sobre el que se desarrolla el proyecto contiene información de los valores de mercado del Litio. Los datos tienen una periodicidad de días laborables, es decir, existen cinco entradas de datos por semana, de lunes a viernes. Además, el conjunto de datos es estructurado, lo que quiere decir que tenemos el mismo esquema para cada una de las entradas que contiene.

2.4.1. Descripción de variables

El conjunto de datos está formado por 10 variables por cada una de las entradas. A continuación, se detalla el significado de cada una de las variables:

- Exchange Date. Es una variable de tipo fecha, con formato DD/MM/AAAA. Hace referencia al día en el que se realiza la entrada, y sus valores están comprendidos entre el 31 de mayo de 2016 y el 29 de agosto de 2022.
- Close. Es una variable de tipo numérico. Muestra el valor de cierre de mercado, en USD.
- Net. Es una variable de tipo numérico. Mide la diferencia entre el valor de mercado de la anterior entrada y el de la actual.
- %Chg. Es una variable de tipo numérico porcentual. Mide la variación porcentual entre el valor de mercado de la anterior entrada y el de la actual.
- Open. Es una variable de tipo numérico. Muestra el valor de apertura de mercado, en USD.
- Low. Es una variable de tipo numérico. Muestra el valor mínimo que alcanzó a lo largo del horario bursátil correspondiente a la fecha del Exchange Date.
- High. Es una variable de tipo numérico. Muestra el valor máximo que alcanzó a lo largo del horario bursátil correspondiente a la fecha del Exchange Date.
- Volume. Es una variable de tipo numérico. Indica el volumen de transacciones realizadas en la fecha del Exchange Date.
- Turnover – USD. Es una variable de tipo numérico. Hace referencia a el valor económico total de todas las transacciones realizadas en la fecha del Exchange Date.
- Flow. Es una variable de tipo numérico. Se demuestra irrelevante para el caso de estudio.

2.5. CRITERIOS DE DESEMPEÑO

2.5.1. Métricas de evaluación

Las métricas de evaluación tienen el fin de medir la exactitud de los valores predichos en relación con los valores reales de la serie temporal.

RMSE

El error de raíz cuadrada media, RMSE por sus siglas en inglés (*Root Mean Squared Error*) se calcula por medio de la siguiente ecuación:

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{n}} \quad (2.19)$$

donde n es el número de observaciones, y_i es el valor real de cada observación e $\hat{y}_i$ es el valor predicho de cada observación.

MAPE

El error medio de porcentaje absoluto, MAPE por sus siglas en inglés (*Mean Absolute Percentage Error*), se calcula por medio de la siguiente ecuación:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)}{y_i} \cdot 100 \quad (2.20)$$

donde, al igual que en el RMSE, n es el número de observaciones, y_i es el valor real de cada observación e $\hat{y}_i$ es el valor predicho de cada observación. El resultado se expresa en valor porcentual.

R^2

El coeficiente de determinación R^2 expresa el porcentaje de la variabilidad total de los datos que es explicada por el modelo. Se calcula por medio de la siguiente expresión:

$$R^2 = 1 - \frac{RSS}{TSS} \quad (2.21)$$

donde RSS es la suma de los cuadrados de las diferencias entre los valores observados y los valores predichos por el modelo (también llamados residuos) y TSS es la suma de los cuadrados de las diferencias entre los valores observados y la media de los valores observados. El resultado de R^2 varía en el intervalo $[0, 1]$, siendo 1 el mejor es el ajuste del modelo a los datos, y 0 el peor.

2.5.2. Pruebas de comprobación de estacionariedad

Antes de aplicar los métodos predictivos seleccionados, es de gran importancia comprobar la estacionariedad de la serie temporal, ya que la presencia de raíces unitarias puede complicar el análisis de una serie temporal y hacer que sea difícil hacer predicciones precisas. Para este propósito, se cuenta con dos pruebas: la Prueba de Dickey-Fuller y la prueba de Phillips-Perron.

Prueba de Dickey-Fuller

La prueba de Dickey y Fuller es un método estadístico que tiene como objetivo determinar si una serie temporal es estacionaria o no. Esto lo consigue determinando la existencia, o inexistencia, de raíces unitarias⁶ en la serie temporal. Las principales pruebas utilizadas son el test de raíces unitarias de Fuller (Fuller, 1976) y el Augmented Dickey-Fuller (ADF) (Dickey & Fuller, 1979).

La prueba se basa en un modelo de regresión en el que se utiliza la serie temporal. Su hipótesis nula es que exista una raíz unitaria y se define de la siguiente manera:

$$y_t = \rho y_{t-1} + \mu + \varepsilon_t \quad (2.22)$$

donde y_t es la variable de interés, ρ y μ son los parámetros de estimación y ε_t es el error en forma de ruido blanco en la serie temporal.

Considerando la anterior formulación, para valores de ρ comprendidos en el intervalo $[-1, 1]$, la serie será estacionaria cuando ρ sea diferente de la unidad. Esto es, cuando $\rho = 1$, la serie es no estacionaria.

Se puede estimar el siguiente modelo para el test ADF:

$$\Delta Y_t = \delta + \gamma Y_{t-1} + \beta_1 t + \sum_{i=2}^p \beta_i \Delta Y_{t-i+1} + \varepsilon_t \quad (2.23)$$

y probar la hipótesis nula de que $\gamma = 0$ (César Alonso, 2010).

Prueba de Phillips-Perron

La prueba de Phillips-Perron, comúnmente abreviada como PP, es una técnica estadística utilizada para verificar si una serie temporal tiene una raíz unitaria y por lo tanto, como se acaba de ver, no es estacionaria (Phillips & Perron, 1988).

El objetivo de esta prueba es el mismo que el de la prueba de Dickey-Fuller, y es usada para corroborar los resultados obtenidos.

⁶ Una raíz unitaria es una solución de la ecuación de un modelo autorregresivo que está en el límite de la estacionariedad; es decir, si la serie tiene una raíz unitaria, no es estacionaria.

2.5.3. Criterios para la obtención del mejor orden ARIMA

Los criterios que se presentan a continuación se emplean para determinar cuál es el mejor orden del modelo ARIMA analizado. Para la obtención del mejor ajuste, se buscará reducir el valor de estos criterios, siendo el de valor más bajo el que identifique el correcto modelo ARIMA.

Akaike's Information Criterion (AIC)

El Criterio de la Información de Akaike se puede describir mediante la siguiente expresión matemática:

$$AIC = -2 \log(L) + 2(p + q + k + 1) \quad (2.24)$$

donde L es la verosimilitud de los datos, $k = 1$ si $c \neq 0$ y $k = 0$ si $c = 0$.

AIC corregido

El AIC corregido se calcula por medio de la siguiente ecuación matemática:

$$AIC_c = AIC + \frac{2(p + q + k + 1)(p + q + k + 2)}{T - p - q - k - 2} \quad (2.25)$$

Bayesian Information Criterion (BIC)

Por último, el Criterio Bayesiano de la Información se define a partir de la expresión matemática descrita a continuación:

$$BIC = AIC + \log(T)(p + q + k + 1) \quad (2.26)$$

3. OBJETIVOS

3.1. OBJETIVO GENERAL

El objetivo general que se busca con la realización de este proyecto es el de establecer una relación entre la evolución del precio del Litio y la evolución del precio del vehículo eléctrico, todo ello enmarcado en el reglamento revisado sobre los límites de las emisiones de CO2 de turismos y furgonetas nuevos (Reglamento (UE) 2023/851, 2023). Se realiza esta comparativa con la finalidad de comprobar la repercusión económica que tendrá la prohibición de la comercialización de turismos y vehículos de reparto nuevos, a partir del año 2035, en base a un análisis multiescenario; así como para contribuir a la labor de concienciación y educación sobre la movilidad sostenible.

3.2. OBJETIVOS ESPECÍFICOS

A continuación, se detallan los objetivos específicos que se buscan con la redacción de este proyecto:

- Generación de un sistema basado en el análisis de grandes cantidades de información de cara a la obtención de patrones de comportamiento de precio.
- Generar modelos predictivos en base a patrones del conjunto de datos.
- Escoger el modelo predictivo que mejor se ajuste, en base a unas métricas definidas.
- Evaluar la idoneidad del conjunto de datos para cada modelo desarrollado.
- Predecir de manera fiable el precio del Litio.
- Extrapolar la predicción del precio del Litio al precio de venta al público de los vehículos eléctricos.
- Considerar otras tecnologías de almacenamiento de energía.
- Contribuir a la concienciación y educación sobre la movilidad sostenible.

4. PLAN DE DESARROLLO DEL PROYECTO

4.1. METODOLOGÍA

A continuación, se detalla ordenadamente la metodología que se sigue para la realización del proyecto:

1. En primer lugar, se escogen dos modelos de predicción diferentes. Para este proyecto se han elegido el modelo SARIMAX (variante del modelo ARIMA) y el modelo Prophet.
2. A continuación, se determina el lenguaje y el entorno de programación en el que se va a desarrollar el apartado técnico del proyecto. Se elige desarrollar el proyecto en Python en Google Colaboratory.
3. Posteriormente, se realiza el tratamiento de datos necesario para la implementación de cada uno de los modelos:
 - a. Designación de variables características. Definir estas variables reduce la complejidad del problema de la predicción y facilita la visualización y comprensión de los resultados.
 - b. Tratamiento de valores nulos. Es necesario realizar un procesamiento de los valores nulos para que los modelos predictivos funcionen correctamente.
 - c. Establecer el formato adecuado para cada tipo de dato de cada variable.
4. Análisis de las características de la serie temporal.
 - a. Determinación de la estacionariedad, o no estacionaria, de la serie temporal. En función del resultado, se deberá aplicar al menos una diferenciación a la serie temporal original si esta no es estacionaria.
5. En este paso, se procede al desarrollo de la predicción, tanto con el modelo Prophet como con el modelo ARIMA.
 - a. En el modelo Prophet se tendrá en cuenta la necesidad de renombrar las columnas del conjunto de datos en función de los requerimientos del modelo.

- b. En el modelo ARIMA se buscará la obtención del mejor ajuste de los parámetros p , d y q . Tras ello se realizará una valoración de los residuales obtenidos, para definir si el modelo propuesto es correcto.
6. Tras haber realizado ambas predicciones, se comparan las diferentes métricas generadas durante el proceso y se elige aquella que tenga un mejor ajuste.
7. Una vez elegida la mejor predicción, se procede a valorar la repercusión de las tendencias observadas, tratando las implicaciones éticas y el impacto social que se ocasionarían, así como aportando una conclusión final del trabajo realizado.

Tras realizar todo el trabajo previamente detallado, se puede contextualizar el precio del EV en el marco del Pacto Verde Europeo y del Objetivo 55.

Con el objetivo de facilitar la comprensión de la metodología seguida entre los pasos 3 y 6, se facilita un flujograma que describe este proceso.




Ilustración 7. Flujograma del proceso técnico. Parte I. Fuente: elaboración propia.




Ilustración 8. Flujograma del proceso técnico. Parte II. Fuente: elaboración propia.

4.2. TECNOLOGÍAS

En este apartado se detallarán los lenguajes y entornos utilizados para el desarrollo del proyecto.

4.2.1. Python

Se utiliza el lenguaje de programación Python para el desarrollo de la parte técnica del proyecto. Python es un lenguaje de alto nivel que destaca por su potencia y su alta integración con otras muchas tecnologías. Se elige este lenguaje de programación por la cantidad de herramientas que existen enfocadas específicamente al desarrollo de proyectos de análisis de datos y series temporales.

Para llevar a cabo el desarrollo de este proyecto, se hace uso de diferentes paquetes de Python. A continuación, se citan las más relevantes:

- Pandas: es un paquete utilizado para el análisis de datos y la manipulación de estos. Es ampliamente utilizada por su velocidad y flexibilidad, entre otras características.
- Numpy: permite la creación de vectores y matrices multidimensionales de gran tamaño. Asimismo, incluye una gran variedad de funciones matemáticas de alto nivel.
- Matplotlib: es una librería que permite la representación de gráficos bidimensionales estáticos, animados o interactivos.
- Statsmodel: permite hacer una exploración de los datos, realizar modelos estadísticos y llevar a cabo tests estadísticos.

statsmodels is a Python module that provides classes and functions for the estimation of many different statistical models, as well as for conducting statistical tests, and statistical data exploration. An extensive list of result statistics are available for each estimator. The results are tested against existing statistical packages to ensure that they are correct.

(statsmodel, s.f.)

Dentro de este paquete, cabe destacar determinados métodos específicos por su especial importancia dentro del proyecto. Estos son:

- `seasonal_decompose` (`statsmodels.tsa.seasonal.seasonal_decompose`): realiza una descomposición estacionaria usando medias móviles.
- `ARIMA` (`statsmodels.tsa.arima.model.ARIMA`): implementa el modelo de predicción descrito en el apartado 2.3.2.
- `plot_acf` (`statsmodels.graphics.tsaplots.plot_acf`): grafica la función de autocorrelación.

- `plot_pafc` (`statsmodels.graphics.tsaplots.plot_pacf`): grafica la función de autocorrelación parcial.
- `pmdarima`: implementa en Python funciones propias del lenguaje de programación R. El método fundamental de este paquete es `auto_arima`:
 - `auto_arima` (`pmdarima.arima.auto_arima`): busca identificar los parámetros más óptimos para un modelo ARIMA, dando como solución un único modelo ARIMA. Este proceso se basa en la función R, `forecast::auto.arima`.
- `Prophet`: en este paquete se encuentra el modelo de predicción descrito en el apartado 2.3.2.

4.2.2. Google Colaboratory

Google Colaboratory, conocido también como Google Colab, es una plataforma de Google que se usará como entorno de programación para el proyecto. Esta herramienta es un servicio de cuaderno de Jupyter que posibilita la ejecución de Python en el navegador.

Se escoge esta herramienta por las ventajas que aporta su uso, de entre las que cabe destacar que no requiere configuración para su uso; que incluye la posibilidad de ejecutar el código sobre la unidad de procesamiento gráfico (GPU) o sobre la unidad de procesamiento tensorial (TPU), mejorando así el desempeño del programa en ejecución; y que permite el uso de librerías populares como las mencionadas en el anterior apartado (Pandas, Matplotlib, ...).

4.3. PLAN DE TRABAJO

A continuación, se incluye el diagrama de Gantt original donde se pueden comprobar el plan de trabajo definido inicialmente. Se puede consultar el diagrama de Gantt final en el siguiente apartado, donde se observan las desviaciones que se han dado durante el desarrollo del proyecto.




Ilustración 9. Diagrama de Gantt inicial del proyecto. Fuente: elaboración propia.

4.4. DESVIACIONES DEL PLAN INICIAL




Ilustración 10. Diagrama de Gantt final del proyecto. Fuente: elaboración propia.

4.5. RECURSOS

Debido a que la parte técnica de este proyecto se aleja de lo impartido en las diferentes asignaturas del grado, ha sido necesario realizar una profunda formación en el campo del Machine Learning y de la predicción de series temporales. De toda la formación llevada a cabo, destacaré la realización de los cursos *“Intro to Machine Learning”* y *“Intermediate Machine Learning”* de la plataforma Kaggle⁷, o el curso *“Complete Python Developer in 2023: Zero to Mastery”* de la plataforma Udemy⁸. En total se han dedicado 77 horas a cuestiones formativas.

Además, para el desarrollo técnico del proyecto, se utiliza el plan sin coste económico de Google Colaboratory (herramienta mencionada en la sección 4.2.2), con las siguientes características:

- Acceso limitado a las GPUs.
- Tiempos de ejecución de GPU y de TPU de hasta 12 horas, en función de la disponibilidad.
- Posibilidad de acceso a máquinas virtuales con una capacidad estándar de memoria del sistema.

4.6. CONDICIONANTES Y LIMITACIONES

El principal condicionante ha sido la obtención de los históricos de precios del Litio. Estos datos han sido obtenidos de la plataforma REFINITIV EIKON⁹. A su vez, este documento también ha sido la principal limitación, ya que solo se disponían de registros hasta el 29 de agosto de 2022, por lo que los resultados que se obtienen tras realizar el trabajo de predicción son, en realidad, valores ya pasados.

Asimismo, como se menciona anteriormente, ha sido necesaria la formación en los diferentes aspectos técnicos del proyecto, invirtiendo una gran cantidad de tiempo en ello, como se menciona en el apartado 4.5.

⁷ Kaggle - <https://www.kaggle.com/> - es una comunidad en línea de Machine Learning y Data Science, con herramientas de aprendizaje.

⁸ Udemy - <https://www.udemy.com/> - es una plataforma de aprendizaje en línea, dirigida a profesionales.

⁹ REFINITIV EIKON - <https://www.refinitiv.com/es/products/eikon-trading-software> - es una plataforma de análisis financiero, que da acceso a información, datos y noticias de diferentes industrias.

5. DESARROLLO DE LA SOLUCIÓN TÉCNICA

5.1. PREPROCESAMIENTO DE DATOS

5.1.1. Elección de variables características

Tal y como se muestra en la Ilustración 11, el conjunto de datos presenta variables muy correlacionadas unas a otras (aquellas cuya autocorrelación se acerca a 1.0000).

	Close	Net	%Chg	Open	Low	High	Volume	Turnover - USD	Flow
Close	1.0000	0.0441	0.0398	0.9964	0.9979	0.9981	-0.0206	0.0772	0.6551
Net	0.0441	1.0000	0.9051	-0.0282	0.0078	0.0169	0.0930	0.0918	0.0562
%Chg	0.0398	0.9051	1.0000	-0.0234	0.0068	0.0168	0.1776	0.1774	0.0613
Open	0.9964	-0.0282	-0.0234	1.0000	0.9974	0.9972	-0.0243	0.0735	0.6521
Low	0.9979	0.0078	0.0068	0.9974	1.0000	0.9961	-0.0361	0.0609	0.6519
High	0.9981	0.0169	0.0168	0.9972	0.9961	1.0000	-0.0096	0.0889	0.6548
Volume	-0.0206	0.0930	0.1776	-0.0243	-0.0361	-0.0096	1.0000	0.9877	-0.0287
Turnover - USD	0.0772	0.0918	0.1774	0.0735	0.0609	0.0889	0.9877	1.0000	0.0548
Flow	0.6551	0.0562	0.0613	0.6521	0.6519	0.6548	-0.0287	0.0548	1.0000

Ilustración 11. Matriz de correlación entre las variables del conjunto de datos. Fuente: elaboración propia.

Por las características del proyecto, la variable que tomaremos como referencia del precio será Close, ya que es un valor característico, en este caso el valor de cierre de mercado. El resto de los valores característicos (Open, Low y High) se omiten sin riesgo de perder información por su alta correlación entre ellos. Además, se elige la variable Exchange Date como índice para el conjunto de datos.

Para dar una explicación analítica a la reducción de la dimensionalidad, se ejecuta un análisis PCA¹⁰ con las variables Close, Open, Low y High para conocer la repercusión de un número fijo de características (en este caso dos) en el conjunto total de los datos. Se obtiene que la primera variable es capaz de representar el 99.79 % de la varianza de los datos del conjunto, y la segunda variable representa el 0.1 %.

Para visualizar este hecho, se vuelve a generar una matriz de correlación, añadiendo la variable que representa el 99.79 % de la varianza del conjunto de datos. Nombramos esta variable como PC1.

	Close	Net	%Chg	Open	Low	High	Volume	Turnover - USD	Flow	PC1
Close	1.0000	0.0440	0.0398	0.9964	0.9979	0.9981	-0.0189	0.0788	0.6587	0.9991
Net	0.0440	1.0000	0.9051	-0.0282	0.0078	0.0169	0.0931	0.0919	0.0556	0.0102
%Chg	0.0398	0.9051	1.0000	-0.0234	0.0068	0.0168	0.1776	0.1775	0.0606	0.0101
Open	0.9964	-0.0282	-0.0234	1.0000	0.9974	0.9972	-0.0223	0.0753	0.6547	0.9988
Low	0.9979	0.0078	0.0068	0.9974	1.0000	0.9961	-0.0341	0.0628	0.6548	0.9989
High	0.9981	0.0169	0.0168	0.9972	0.9961	1.0000	-0.0080	0.0904	0.6583	0.9990
Volume	-0.0189	0.0931	0.1776	-0.0223	-0.0341	-0.0080	1.0000	0.9879	-0.0157	-0.0204
Turnover - USD	0.0788	0.0919	0.1775	0.0753	0.0628	0.0904	0.9879	1.0000	0.0658	0.0773
Flow	0.6587	0.0556	0.0606	0.6547	0.6548	0.6583	-0.0157	0.0658	1.0000	0.6574
PC1	0.9991	0.0102	0.0101	0.9988	0.9989	0.9990	-0.0204	0.0773	0.6574	1.0000

Ilustración 12. Matriz de correlación entre las variables del conjunto de datos y la variable PC1.

Fuente: elaboración propia.

Se comprueba que, efectivamente, las variables Close, Open, Low y High están profundamente correlacionadas con la variable PC1. Con este análisis, queda validada la reducción de dimensionalidad del conjunto de datos.

5.1.2. Tratamiento de valores nulos

Para realizar todos los procesos necesarios hasta poder llegar al resultado de la predicción de la serie temporal, es necesario que no exista ningún valor nulo a lo largo de todo el conjunto de datos.

¹⁰ El Análisis de Componentes Principales (PCA) permite simplificar un espacio muestral multidimensional en otro espacio muestral, equivalente, de dimensiones reducidas. La mejor manera de efectuar esta reducción es realizar una proyección en el subespacio que captura la mayor variación de los datos.

Existen varios métodos que se pueden emplear para evitar este hecho. Se elige el método “ffill”, que permite utilizar el próximo valor válido para rellenar el nulo. Se opta por esta solución por ser la menos agresiva con la integridad del conjunto de datos.

Además, para implementar el método que ofrece Prophet, es necesario proporcionar al modelo únicamente dos columnas: una primera que sirva como índice del conjunto de datos (serán las fechas de las entradas de datos) y una segunda que sea el valor numérico de cada entrada. Asimismo, es necesario otorgar un nombre concreto a estas columnas (“ds” e “y”, respectivamente).

Puesto que el método ARIMA no presenta ninguna restricción de este tipo, pero tampoco se ve afectado por los cambios necesarios para el modelo Prophet, se opta por mantener el mismo conjunto de datos para ambas soluciones, con el fin de reducir la complejidad del proyecto.

5.2. ANÁLISIS DE LA SERIE TEMPORAL

5.2.1. Representación de la serie temporal

El primer paso para poder identificar ciertas componentes útiles para el análisis de la serie temporal es representar gráficamente el conjunto de datos. De esta forma se consigue un primer análisis visual de factores importantes como las tendencias que siguen los datos a lo largo del tiempo.




Ilustración 13. Representación gráfica de la serie temporal. Fuente: elaboración propia.

5.2.2. Descomposición de la serie temporal

Del mismo modo, se procede a representar las características principales de la serie temporal, mediante una descomposición de los datos, usando medias móviles. El motivo de realizar esta descomposición es conseguir aislar determinadas componentes de la serie temporal, eliminar la tendencia y así poder visualizar el componente periódico.




Ilustración 14. Descomposición de la serie temporal original. Fuente: elaboración propia.

De la observación directa del resultado generado tras la descomposición, se derivan las siguientes conclusiones:

1. La tendencia del conjunto de datos no es constante. Como se ha expuesto en el apartado 2.3.1, de esta observación se puede deducir que la serie temporal no es estacionaria.
2. Tiene una fuerte componente periódica. Se puede observar que el conjunto de datos tiene una periodicidad semanal.
3. Residuo. Es una variable sensible a los shocks (alteraciones no previstas de los valores en la serie temporal). Así, se puede comprobar que, los puntos en los que el residuo toma valores muy diferentes entre sí son puntos en los que los datos han tomado valores no previstos (de Jong & Penzer, 1998).

5.2.3. Comprobación de la estacionariedad de la serie temporal

Como ya se ha visto en el apartado 2.5.2, comprobaremos la estacionariedad, o no estacionariedad, de la serie temporal por medio de dos métodos: la prueba de Dickey-Fuller y la prueba de Phillips-Perron.

	RESULTADO DE LA PRUEBA	VALOR CRÍTICO AL 5 %	P-VALOR
ADF	-2.033	-2.86	0.272
PP	-1.850	-2.86	0.356

*Tabla 1. Resultados de las pruebas ADF y PP para comprobar la estacionariedad de la serie temporal.
Fuente: elaboración propia.*


Para interpretar estos resultados se tendrá en cuenta que, si el valor de cada una de las pruebas es menor a su valor crítico correspondiente (en este caso se ha establecido al 5 %), se rechaza la hipótesis nula de la existencia de una raíz unitaria, por lo que se afirma que la serie es estacionaria.

En este caso, ambos resultados de las pruebas estadísticas son mayores que sus valores críticos correspondientes, por lo que queda probada la hipótesis nula de ambas pruebas y, por tanto, se concluye que la serie temporal analizada no es estacionaria.

También se puede atender al p-valor de cada prueba. Al obtener un p-valor mayor a 0.05 la hipótesis nula no se rechaza, por lo que se concluye que la serie original no es estacionaria.

5.3. PREDICCIÓN CON MODELO PROPHET

Para poder llevar a cabo la predicción del modelo Prophet con mayores garantías de éxito es necesario aportar como entrada una serie temporal estacionaria. Tras haber comprobado que la serie que se está analizando no es estacionaria, se le aplica una diferenciación y se obtienen los resultados representados en la siguiente ilustración:



*Ilustración 15. Descomposición estacional de la serie temporal con una diferenciación aplicada.
Fuente: elaboración propia.*

Como se desarrolla en el siguiente apartado, tras este análisis de la serie con una diferenciación aplicada, se realiza la predicción de los valores futuros de la serie temporal.

5.4. PREDICCIÓN CON MODELO SARIMAX

El primer paso que se lleva a cabo para ajustar los parámetros del modelo ARIMA es comprobar los valores de autocorrelación y de autocorrelación parcial de la serie temporal.




Ilustración 16. Autocorrelación de la serie temporal. Fuente: elaboración propia.

A la vista de los resultados, se observa que los valores del conjunto de datos están muy correlacionados entre sí. Esta correlación es elevada, aunque va disminuyendo conforme aumenta el retraso (el lag). Como consecuencia, y tal y como se ha comprobado previamente en el apartado 5.2.3 mediante las pruebas de Dickey-Fuller y de Phillips-Perron, es necesario aplicar al menos una diferenciación a la serie temporal.

Se aplican una y dos diferenciaciones para ver cómo evolucionan los valores de autocorrelación.




Ilustración 17. Autocorrelaciones de la serie temporal con una y con dos diferenciaciones aplicadas. Fuente: elaboración propia.

Se comprueba que, tras aplicar una diferenciación, los valores de autocorrelación disminuyen y oscilan en el umbral adecuado. Sin embargo, al aplicar la segunda diferenciación, comprobamos que los valores de autocorrelación siguen bajos, pero se generan valores alejados del umbral. Por tanto se concluye que solo será necesario aplicar una diferenciación a nuestra serie temporal. A continuación, se generan las autocorrelaciones parciales de primera diferenciación de la serie temporal, que se comportan de la misma manera que las autocorrelaciones vistas anteriormente, por lo que confirman las conclusiones obtenidas.




Ilustración 18. Autocorrelación parcial de la serie temporal con una diferenciación aplicada. Fuente: elaboración propia.

Se aplica la función “auto_arima” a la serie temporal y se obtiene el ajuste del modelo ARIMA más óptimo para los parámetros establecidos. Se obtiene el siguiente resultado:

```

SARIMAX Results
=====
Dep. Variable:          y      No. Observations:          1630
Model:          SARIMAX(2, 1, 2)  Log Likelihood          2244.393
Date:          Tue, 04 Apr 2023  AIC          -4478.785
Time:          08:59:49        BIC          -4451.807
Sample:          05-31-2016      HQIC          -4468.776
- 08-29-2022
Covariance Type:          opg
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          1.3067        0.020      65.335      0.000         1.267         1.346
ar.L2         -0.9151        0.020     -45.980      0.000        -0.954        -0.876
ma.L1         -1.3311        0.015     -87.194      0.000        -1.361        -1.301
ma.L2          0.9609        0.015      62.478      0.000         0.931         0.991
sigma2          0.0037     5.73e-05      64.916      0.000         0.004         0.004
=====
Ljung-Box (L1) (Q):          0.28  Jarque-Bera (JB):          5190.03
Prob(Q):          0.60  Prob(JB):          0.00
Heteroskedasticity (H):          4.50  Skew:          0.50
Prob(H) (two-sided):          0.00  Kurtosis:          11.69
=====

```

Ilustración 19. Resultados de la ejecución de la función "auto_arima" en la serie temporal. Fuente: elaboración propia.

Una vez se obtiene el modelo ARIMA más ajustado, en este caso es un modelo SARIMAX (2, 1, 2), se procede a realizar la predicción de la serie temporal. Sin embargo, esta predicción resulta fallida, tal como se muestra en la Ilustración 19.

Debido al resultado que se obtiene, representado en la siguiente ilustración, se concluye que los datos aportados al modelo son insuficientes para que éste realice una predicción de la serie temporal.




Ilustración 20. Predicción de la serie original con el modelo SARIMAX (2, 1, 2). Fuente: elaboración propia.

Para solucionar este inconveniente, se procede a aumentar el número de datos por la técnica de interpolación (Franke, 1982). Estas técnicas han demostrado tener gran eficacia a la hora de suplir datos faltantes de series temporales insuficientes. De este modo, se incluyen 1046 nuevas observaciones (esto es, un incremento del 64,17 % sobre la cantidad de datos previa) generadas a partir de las existentes y se vuelve a realizar el proceso anteriormente descrito.

Se vuelve a ejecutar la función “auto_arima” a la serie temporal aumentada y se obtiene el nuevo ajuste del modelo SARIMAX, descrito a continuación:

```

SARIMAX Results
=====
Dep. Variable:          y      No. Observations:          2676
Model:                 SARIMAX(0, 1, 2)      Log Likelihood          5971.298
Date:                  Tue, 16 May 2023      AIC                      -11936.597
Time:                  18:25:13              BIC                      -11918.921
Sample:                0                    HQIC                   -11930.202
                        - 2676
Covariance Type:       opg
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ma.L1          0.7695      0.010      79.281      0.000      0.750      0.789
ma.L2          0.0615      0.009       6.752      0.000      0.044      0.079
sigma2         0.0007      7.39e-06     91.086      0.000      0.001      0.001
=====
Ljung-Box (L1) (Q):          0.01      Jarque-Bera (JB):          12286.83
Prob(Q):                    0.91      Prob(JB):                  0.00
Heteroskedasticity (H):      4.67      Skew:                      0.36
Prob(H) (two-sided):         0.00      Kurtosis:                  13.47
=====

```

Ilustración 21. Resultados de la ejecución de la función "auto_arima" en la serie temporal aumentada. Fuente: elaboración propia.

5.4.1. Validación del modelo

Se realiza un análisis de residuales con el fin de validar el modelo escogido. Los residuales, o residuos, en un análisis de una serie temporal son las diferencias que existen entre los valores observados y los valores predichos por el modelo (Brockwell, 2016). Gracias a su análisis se podrá verificar las siguientes características del modelo elegido (Chatfield, 2016):

1. Verificar la estacionalidad. Al igual que la propia serie temporal, los residuos deben ser estacionarios.
2. Evaluar la independencia. Los residuos deben ser independientes entre sí. Esto es, no debe existir una autocorrelación significativa entre ellos y si la existiera

significaría que el modelo elegido no captura toda la información importante de la serie temporal.

3. Comprobar la normalidad. Los residuos deben seguir una distribución normal. En caso de no seguirla se debería aplicar nuevas transformaciones a la serie.

Estacionariedad de los residuos

En la figura que aparece a continuación se puede intuir la estacionariedad de los residuos del modelo. Se comprobará esta afirmación con el correlograma del siguiente apartado.




Ilustración 22. Residuos del modelo SARIMAX(0,1,2). Fuente: elaboración propia.

Autocorrelación de los residuos

Se confirma la hipótesis generada en el anterior apartado, comprobando que no existe una autocorrelación significativa en los residuos del modelo elegido.




Ilustración 23. Autocorrelaciones de los residuos del modelo SARIMAX(0,1,2). Fuente: elaboración propia.

Normalidad de los residuos

Se utiliza un gráfico Q-Q para valorar la normalidad de los residuos. Este tipo de diagramas se utiliza para comparar la distribución de una variable (en este caso los residuales del modelo utilizado) con una distribución teórica de referencia, comparando sus cuantiles (Wilcox, 2017).




Ilustración 24. Gráfico de densidad para evaluar la normalidad de los residuos del modelo SARIMAX(0,1,2). Fuente: elaboración propia.

Se comprueba que los residuos del modelo SARIMAX(0,1,2) se ajustan de forma suficiente a una distribución normal, por lo que se confirma la normalidad de los términos de error. Las desviaciones que se observan en los primeros y últimos cuantiles se deben a la alta frecuencia con la que se observan los valores más frecuentes de la serie, como se puede observar en el histograma que se presenta a continuación.




Ilustración 25. Histograma de los residuos del modelo SARIMAX(0,1,2) con la densidad estimada. Fuente: elaboración propia.

Se concluye que no existen patrones en los residuos y que el ajuste del modelo es correcto tras el análisis de residuales del modelo predictivo utilizado.

A continuación, se muestra una representación gráfica de la relación entre los valores observados y los valores ajustados por el modelo SARIMAX.




Ilustración 26. Relación de ajuste entre los valores observados y los valores ajustados por el modelo SARIMAX. Fuente: elaboración propia.

6. RESULTADOS

6.1. RESULTADOS DEL MÉTODO PROPHET

Después de ejecutar el método Prophet sobre la serie temporal diferenciada, se obtienen los siguientes valores de métricas de evaluación:

$$RMSE = 0.062157$$

$$MAPE = 0.160584$$

A continuación, se muestra la predicción de la serie temporal diferenciada con este modelo. la línea azul oscura representa el valor del precio predicho y el sombreado azul indica los intervalos de confianza superiores e inferiores.




Ilustración 27. Predicción de la serie temporal diferenciada con el modelo Prophet. Fuente: elaboración propia.


Debido a la relativa escasez de datos en el conjunto se recurre a la validación cruzada con el objetivo de aumentar la precisión del modelo.

6.2. RESULTADOS DEL MÉTODO SARIMAX

Tras la ejecución del método SARIMAX sobre la serie temporal aumentada, se obtienen los siguientes valores de métricas de evaluación:

$$RMSE = 0.022808$$

$$MAPE = 0.134795$$



*Ilustración 28. Resultados de la predicción. En azul, los datos históricos; en naranja, los predichos.
Fuente: elaboración propia.*

6.3. COMPARATIVA DE MÉTRICAS PROPHET Y SARIMAX

Se realiza una comparación de las métricas de evaluación obtenidas de la ejecución de los modelos Prophet y SARIMAX, respectivamente. Se evalúan las métricas RMSE y MAPE, representadas en la siguiente tabla comparativa:

	RMSE	MAPE
PROPHET	0.062157	0.160584
SARIMAX	0.022808	0.134795

Tabla 2. Comparación de métricas de evaluación para los modelos Prophet y SARIMAX. Fuente: elaboración propia.




Ilustración 29. Comparativa de métricas de evaluación. Fuente: elaboración propia.

A la vista de los resultados obtenidos, se puede afirmar que el modelo SARIMAX realiza un mejor ajuste, por lo que su predicción va a ser más fiable que la del modelo Prophet.

6.4. ANÁLISIS DE TENDENCIA FUTURA

Tras haber realizado la predicción de los valores futuros con el modelo que proporcionaba las mejores métricas de evaluación, se procede al análisis de la tendencia que resulta de los nuevos valores predichos.




Ilustración 30. Detalle de los valores predichos. Fuente: elaboración propia.

Tal y como se muestra en la anterior ilustración, la tendencia del precio del Litio predicha es bajista. Se calcula una reducción del 22,52 % en el valor del Litio entre el último valor observado y el último valor predicho.

Asimismo, el resultado parece ir en consonancia con la intuición. Esta afirmación no es despreciable ya que los pronósticos basados en juicios son altamente empleados a la hora de ajustar pronósticos estadísticos. Este hecho es constatado por el artículo *Judgemental Forecasting: A Review of Progress over the Last 25 Years*:

“Mientras que anteriormente se pensaba que el juicio era enemigo de la precisión, hoy en día se reconoce que el juicio es un componente indispensable de la previsión”.

(Lawrence, Goodwin, O’Connor, & Önköl, 2006).

6.5. EXTRAPOLACIÓN DE LA PREDICCIÓN AL PRECIO DE VENTA AL PÚBLICO DEL VEHÍCULO ELÉCTRICO

La extrapolación del precio de venta al público de los vehículos eléctricos se realiza a partir de la predicción del precio del Litio, considerando que este metal desempeña un papel fundamental en la producción de las baterías utilizadas en los vehículos eléctricos. Se asume que los cambios en el precio del Litio pueden influir en el costo de producción de las baterías y, por lo tanto, en el precio final de los vehículos eléctricos.

Para llevar a cabo esta extrapolación, se utiliza un enfoque que tiene en cuenta el precio proyectado del Litio y su relación con el costo de las baterías de vehículos eléctricos. Se deben considerar varios factores adicionales que pueden afectar el precio de venta al público de los vehículos eléctricos, como los avances tecnológicos, las políticas gubernamentales y las economías de escala en la producción de vehículos eléctricos y sus componentes.

En primer lugar, se analiza la relación entre el precio del Litio y el costo de producción de las baterías (Holmberg, 2020). Se consideran estudios y análisis económicos previos que han examinado esta relación (Shafiullah, 2019). Estos estudios han demostrado que el precio del Litio puede tener un impacto significativo en el costo de las baterías de vehículos eléctricos, debido a su uso en la tecnología de baterías de iones de Litio.

Se debe tener en cuenta que también existen otros componentes y materiales en la producción de baterías, por lo que se realiza un análisis más completo considerando todos estos factores.

Por tanto, a la vista de los resultados descritos en el apartado anterior, se concluye que el precio de venta al público del vehículo eléctrico seguirá una tendencia bajista. Gracias al informe redactado por BloombergNEF (BloombergNEF, 2021), además de observarse cómo se mantiene la tendencia bajista en el corto plazo, también se puede observar cómo se mantiene esta tendencia en el largo plazo, llegando a situarse el precio del vehículo eléctrico de batería (BEV) por debajo del precio del vehículo de combustión (ICE) en todos los segmentos de vehículos y furgonetas. En el Anexo C se representan las tendencias mencionadas de los diferentes segmentos de vehículos.

7. IMPLICACIONES ÉTICAS E IMPACTO SOCIAL

El proyecto que se ha desarrollado a lo largo del presente documento tiene profundas implicaciones éticas y un impacto social significativo. Estas implicaciones están relacionadas con la transición hacia la descarbonización del parque automovilístico, la sostenibilidad de los recursos naturales y el fomento de una conciencia global sobre la escasez de materias primas. A continuación, se examinarán estos aspectos en mayor detalle.

7.1. DESCARBONIZACIÓN DEL PARQUE AUTOMOVILÍSTICO

La descarbonización del parque automovilístico es uno de los desafíos más apremiantes en la actualidad y tiene como objetivo último reducir las emisiones de gases de efecto invernadero y mitigar el cambio climático. Los vehículos eléctricos se han reconocido como una solución clave en esta transición hacia una movilidad más sostenible (Höök & Tang, 2013). Al predecir y valorar el precio de venta al público de los vehículos eléctricos, el proyecto contribuye directamente a esta agenda de descarbonización, alienta la adopción de vehículos eléctricos y promueve un cambio hacia sistemas de transporte más limpios y eficientes.

Asimismo, existe la problemática de la masificación de los principales núcleos urbanos, lo que resulta en la necesidad de adaptar el paradigma automovilístico actual en favor de uno más sostenible, impulsado por el uso del transporte público y de vehículos compartidos no contaminantes. Estas son las premisas sobre las que se asienta el concepto *Mobility as a Service* (MaaS), clave en el futuro de la movilidad (Mladenović, 2021).

7.2. CONCIENCIACIÓN SOBRE LA ESCASEZ DE MATERIAS PRIMAS

El Litio es una materia prima esencial para la fabricación de baterías de iones de Litio utilizadas en vehículos eléctricos. A medida que la demanda de vehículos eléctricos aumenta, también crece la necesidad de Litio y otros minerales críticos. La extrapolación del precio del Litio al precio de venta al público de los vehículos eléctricos destaca la

importancia de comprender y abordar la escasez de materias primas. Esto implica promover prácticas sostenibles en la extracción y producción de minerales, así como fomentar la investigación y el desarrollo de tecnologías alternativas y la reutilización de materiales para reducir la dependencia de recursos limitados (Simon, 2018).

Este proyecto se encuentra enmarcado en este propósito de deseo de visibilidad de la realidad presente y futura de la movilidad eléctrica. Asimismo, se busca una democratización del conocimiento relativo a este campo con el fin de que la población gane capacidad de decisión informada.

7.3. EQUIDAD Y ACCESIBILIDAD

El impacto social del proyecto también se relaciona con la equidad y la accesibilidad de los vehículos eléctricos. A medida que se predice y valora el precio de venta al público, es esencial considerar la equidad en la transición hacia la movilidad eléctrica. Esto implica abordar las barreras económicas y sociales que pueden limitar el acceso a los vehículos eléctricos para ciertos grupos de la población. Además, se deben tener en cuenta las políticas y medidas adecuadas para garantizar que la transición hacia los vehículos eléctricos beneficie a todas las comunidades y no perpetúe las desigualdades existentes.

7.4. EDUCACIÓN Y CONCIENCIACIÓN PÚBLICA

El proyecto también desempeña un papel en la educación y la concienciación pública sobre la importancia de la movilidad sostenible y las implicaciones ambientales y sociales asociadas. A través de la extrapolación del precio del Litio, se puede destacar la interconexión entre la industria automotriz, la sostenibilidad de los recursos y la necesidad de reducir las emisiones de gases de efecto invernadero. La divulgación de los resultados del proyecto y la promoción de la concienciación pública contribuyen a un cambio de mentalidad y al fomento de prácticas más sostenibles en el uso de recursos y la elección de transporte.

8. CONCLUSIONES

Basado en el análisis de la extrapolación del precio de venta al público de los vehículos eléctricos utilizando la predicción del precio del Litio, se pueden obtener las siguientes conclusiones:

1. Impacto significativo del precio del Litio: El precio del Litio tiene un efecto significativo en el costo de producción de las baterías utilizadas en los vehículos eléctricos. Se espera que los cambios que se produzcan en el precio del Litio se traduzcan en cambios proporcionales en el precio de venta al público de los vehículos eléctricos.
2. Tendencia a la baja del precio del Litio: La predicción del precio del Litio indica una tendencia a la baja de un 22,52 % en el intervalo de valores predichos. Esto implica que se espera que los precios de las baterías de vehículos eléctricos disminuyan en el futuro, lo cual puede hacer que los vehículos eléctricos sean más asequibles y competitivos en el mercado automotriz.
3. Otros factores influyentes: Es importante tener en cuenta que el precio del Litio no es el único factor que determina el precio final de los vehículos eléctricos. Es por ello por lo que también se deben considerar otros factores, tales como los avances tecnológicos en las baterías, la demanda que experimenta el mercado, las políticas gubernamentales, la evolución de precios de otros minerales determinantes como el Cobalto y las economías de escala existentes en la producción.
4. Incertidumbre y volatilidad: La extrapolación del precio de venta al público de los vehículos eléctricos basada en el precio del Litio está sujeta a un cierto grado de incertidumbre y volatilidad. Las proyecciones futuras realizadas en este proyecto pueden verse afectadas por cambios en el mercado global del Litio, por avances tecnológicos inesperados, así como por otros factores impredecibles.

Se concluye que la extrapolación del precio de venta al público de los vehículos eléctricos basada en la predicción del precio del Litio sugiere una tendencia a la baja en los precios de los vehículos eléctricos debido a la disminución proyectada en el costo de las baterías. Sin embargo, se debe tener en cuenta que este análisis es una estimación y está sujeto a múltiples factores e incertidumbres. Se recomienda realizar análisis adicionales y considerar otros factores relevantes para obtener una evaluación más completa y precisa del impacto del precio del Litio en el precio de venta al público de los vehículos eléctricos.

9. OTROS MÉRITOS DEL PROYECTO

Este proyecto quedará sintetizado en un formato de revista científica para que pueda estar disponible al público en general y contribuir así a la concienciación y el conocimiento, cuya importancia queda expuesta en el apartado 7 de este documento.

Además, para seguir contribuyendo a esta concienciación, se han realizado publicaciones en la red social LinkedIn tratando las implicaciones sociales y éticas del proyecto, así como sus principales conclusiones. Se adjuntan estas publicaciones en el Anexo D.

10. BIBLIOGRAFÍA

- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Trans. Autom. Control*, 716-723.
- Andrieu, C., De Freitas, N., Doucet, A., & I. Jordan, M. (2003). An Introduction to MCMC for Machine Learning. *Kluwer Academic Publishers*.
- Asian Development Bank. (2021). *The 14th Five-Year Plan of the People's Republic of China—Fostering High-Quality Development*. Obtenido de <https://www.adb.org/sites/default/files/publication/705886/14th-five-year-plan-high-quality-development-prc.pdf>
- Bayes, T. (1763). An Essay towards solving a Problem in the Doctrine of Chances. *Philosophical Transactions of the Royal Society of London*.
- BloombergNEF. (2021). *Hitting the EV Inflection Point. Electric vehicle price parity and phasing out combustion vehicle sales in Europe*. Recuperado el 2 de Junio de 2023, de https://www.transportenvironment.org/wp-content/uploads/2021/08/2021_05_05_Electric_vehicle_price_parity_and_adoption_in_Europe_Final.pdf
- BOE. (21 de Mayo de 2021). Ley 7/2021, de 20 de mayo, de cambio climático y transición energética. Obtenido de <https://www.boe.es/eli/es/l/2021/05/20/7>
- Box, G. E., & Jenkins, G. M. (1970). *Time series analysis: forecasting and control*. San Francisco, CA.
- Brockwell, P. J. (2016). *Introduction to time series and forecasting* (3rd edition ed.). Springer.
- César Alonso, J. (2010). Tutorial para Pruebas de Raíces Unitarias: Dickey-Fuller Aumentado y Phillips Perron en EasyReg. *ResearchGate*.
- Chatfield, C. (2016). *The analysis of time series: an introduction*. (6th edition ed.). CRC Press.

- Consejo Europeo. (6 de Diciembre de 2022). *Pacto Verde Europeo - Consilium*. Obtenido de <https://www.consilium.europa.eu/es/policies/green-deal/>
- Consejo Europeo. (26 de Mayo de 2023). *Fit for 55 - The EU's plan for a green transition - Consilium*. Obtenido de <https://www.consilium.europa.eu/es/policies/green-deal/fit-for-55-the-eu-plan-for-a-green-transition/>
- Consejo Europeo. (29 de Marzo de 2023). *Fit for 55: Why the EU is toughening CO2 standards for cars and vans*. Obtenido de <https://www.consilium.europa.eu/en/infographics/fit-for-55-emissions-cars-and-vans/>
- Cox, D., & Miller, H. (1970). *The Theory Stochastic Processes*.
- de Jong, P., & Penzer, J. (1998). Diagnosing Shocks in Time Series. *Journal of the American Statistical Association*, 796-806.
- Deloitte. (2021). *Ley 7/2021, de 20 de mayo, de cambio climático y transición energética*. Recuperado el 29 de Mayo de 2023, de Alert: <https://www2.deloitte.com/es/es/pages/legal/articles/ley-7-2021-cambio-climatico-transicion-energetica.html>
- Deng, J. B. (2020). Electric vehicles batteries: requirements and challenges. *Joule* , 511-515.
- Devijver, P. A., & Kittler, J. (1982). *Pattern Recognition: A Statistical Approach*. Londres: Prentice-Hall.
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the Estimators for Autoregressive Time Series with a Unit Root. *Journal of the American Statistical Association*, 427-431.
- Facebook Open Source. (s.f.). *Prophet | Forecasting at scale*. Obtenido de <https://facebook.github.io/prophet/>
- Ferrovial. (2021). *Ley de Cambio Climático y Transición Energética - Ferrovial*. Recuperado el 29 de Mayo de 2023, de <https://www.ferrovial.com/es/recursos/ley-de-cambio-climatico-y-transicion-energetica/>
- Flach, P. (2012). *Machine Learning: The Art and Science of Algorithms*. Cambridge University Press.
- Franke, R. (1982). Scattered data interpolation: tests of some methods. *Mathematics of Computation*, 181-200. Obtenido de <https://www.ams.org/journals/mcom/1982-38-157/S0025-5718-1982-0637296-4/S0025-5718-1982-0637296-4.pdf>

- Friedman, J., & Stuetzle, W. (1981). Projection Pursuit Regression. *Journal of the American Statistical Association* 76, 817–823. doi:10.1080/01621459.1981.10477729
- Fuller, W. A. (1976). *Introduction to Statistical Time Series*. Nueva York.
- Gelman, A. (2002). Prior distribution. En *Encyclopedia of Environmetrics* (págs. 1634-1637).
- Hao, H. Y., & Sarkis, J. (2016). Carbon footprint of global passenger cars: secenarios through 2050. *Energy*, 121-31.
- Harvey, A. C., & Peters, S. (1990). Estimation Procedures for Structural Time Series Models. *Journal of Forecasting*.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 1735-1780.
- Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. *Neural computation*.
- Holmberg, P. &. (2020). *The impact of lithium and cobalt prices on electric vehicle battery costs: A cross-country analysis*.
- Höök, M., & Tang, X. (2013). Depletion of fossil fuels and anthropogenic climate change—A review. *Energy Policy*, 797-809.
- Hyndman, R., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (Tercera ed.). OTexts. Obtenido de <https://otexts.com/fpp3/>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning*.
- Lawrence, M., Goodwin, P., O'Connor, M., & Önkál, D. (2006). Judgmental forecasting: A review of progress over the last 25 years. *International Journal of Forecasting* 22, 493-518. doi:<http://dx.doi.org/10.1016/j.ijforecast.2006.03.007>
- Liu, L. M., Hudak, G. B., Box, G., Muller, M., & Tiao, G. (1992). *Forecasting and time series analysis using the SCA statistical system* . Chicago, Illinois: Scientific Computing Associates Corp.
- Liu, L., Hudak, G., Box, G., Muller, M., & Tiao, G. (1997). *Forecasting and time series analysis using the SCA statistical system vol. 2*.
- Meyn, S. P., & Tweedie, R. L. (1993). *Markov Chains and Stochastic Stability*.

- Mladenović, M. N. (2021). Mobility as a Service. *International Encyclopedia of Transportation.*, 12-18. doi:doi:10.1016/B978-0-08-102671-7.10607-4
- Naciones Unidas. (s.f.). *El Acuerdo de París* | Naciones Unidas. Obtenido de <https://www.un.org/es/climatechange/paris-agreement>
- Olivetti, E. A. (2017). Lithium-ion battery supply chain considerations: analysis of potential bottlenecks in critical metals. . *Joule* , 229-243.
- Phillips, P. C., & Perron, P. (1988). Testing for a unit root in time series regression. *BIOMETRIKA*, 335–346.
- Refaeilzadeh, P., Tang, L., & Lui, H. (6 de Noviembre de 2008). k-fold Cross-Validation. *Arizona State University*. Obtenido de <https://web.archive.org/web/20110905044421/http://www.public.asu.edu/~ltang9/papers/ency-cross-validation.pdf>
- Reglamento (UE) 2019/631. (17 de Abril de 2019). Reglamento (UE) 2019/631 del Parlamento Europeo y del Consejo, de 17 de abril de 2019, por el que se establecen normas de comportamiento en materia de emisiones de CO₂ de los turismos nuevos y de los vehículos comerciales ligeros nuevos.
- Reglamento (UE) 2023/851. (19 de Abril de 2023). Reglamento (UE) 2023/851 del Parlamento Europeo y del Consejo de 19 de abril de 2023 por el que se modifica el Reglamento (UE) 2019/631 en lo que respecta al refuerzo de las normas de comportamiento en materia de emisiones de CO₂ .
- Rhif, M., Ben Abbes, A., Riadh Farah, I., Martínez, B., & Sang, Y. (2019). *Wavelet Transform Application for/in Non-Stationary Time-Series Analysis: A Review*. MDPI - Applied Physics Section. Obtenido de <https://www.mdpi.com/2076-3417/9/7/1345>
- Servicio Geológico de EE. UU. (2022). *Resúmenes de materias primas minerales 2022*.
- Shafiullah, G. M. (2019). Lithium-ion Batteries for Electric Vehicles: The Journey So Far and the Challenges Ahead. *Energies*.
- Simon, F. G. (2018). Lithium availability and future production outlooks. *Resources Policy*, 106-116.
- statsmodel. (s.f.). Obtenido de Introduction - statsmodel: <https://www.statsmodels.org/stable/index.html>
- Taylor, S. J., & Letham, B. (2017). Forecasting at Scale. *PeerJ*.

- Weil, M. Z. (2018). The Issue of Metal Resources in Li-Ion Batteries for Electric Vehicles. *Behaviour of Lithium-Ion Batteries in Electric Vehicles: Battery Health, Performance, Safety, and Cost*, 59-74.
- Wilcox, R. R. (2017). *Introduction to Robust Estimation and Hypothesis Testing* (4th edition ed.). Academic Press.
- Xu, C. D. (2020). Future material demand for automotive lithium-based batteries. *Communications Mater*, 99.
- Young, W. L. (1977). The Box-Jenkins approach to time series analysis and forecasting: principles and applications. *RAIRO. Recherche opérationnelle*, 129-143.
- Ziemann, S., B. Müller, D., Liselotte, S., & Weil, M. (2018). Modeling the potential impact of lithium recycling from EV batteries on lithium demand: A dynamic MFA approach. *Resources, Conservation and Recycling*, 76-85.
doi:<https://doi.org/10.1016/j.resconrec.2018.01.031>

ANEXO A: EXPLORATORY DATA ANALYSIS (EDA)




Ilustración 31. Histograma de las variables del conjunto de datos. Fuente: elaboración propia.




Ilustración 32. Diagrama de caja de las variables Close, Net, %Chg y High. Fuente: elaboración propia.




Ilustración 33. Diagrama de caja de las variables Volume, Turnover - USD y Flow. Fuente: elaboración propia.




Ilustración 34. Relaciones por pares del conjunto de datos. Fuente: elaboración propia.

ANEXO B: MUESTRA DE LAS VARIABLES

Exchange Date	Close	Net	%Chg	Open	Low	High	Volume	Turnover - USD	Flow
29-ago-2022	1,2418	+0,0169	+1,3813 %	1,2090	1,1949	1,2418	7.867	9.530,1020	3.556.596,1117
26-ago-2022	1,2248	-0,0410	-3,2362%	1,2530	1,2108	1,2530	4.778	5.845,4174	3.552.359,3927
25-ago-2022	1,2658	-0,0353	-2,7114%	1,3036	1,2280	1,3036	11.482	14.154,2763	3.581.161,6208
24-ago-2022	1,3011	+0,0116	+0,8971 %	1,2822	1,2634	1,3011	7.911	10.119,1711	3.588.400,9155
23-ago-2022	1,2895	+0,0230	+1,8179 %	1,3036	1,2754	1,3036	1.898	2.435,9481	3.572.353,9796
22-ago-2022	1,2665	-0,0841	-6,2243%	1,2992	1,2665	1,3179	2.258	2.918,9917	3.544.992,7703
19-ago-2022	1,3505	+0,0312	+2,3656 %	1,3458	1,3080	1,3505	1.629	2.181,6533	3.584.971,4449
18-ago-2022	1,3193	-0,0404	-2,9726%	1,3336	1,3193	1,3574	1.271	1.691,7992	3.613.710,9224
17-ago-2022	1,3598	-0,0338	-2,4261%	1,3887	1,3598	1,3887	1.114	1.516,9487	3.660.100,5979
16-ago-2022	1,3936	-0,0003	-0,0213%	1,3936	1,3887	1,3984	2.369	3.309,7201	3.674.480,6207
15-ago-2022	1,3939	-0,0300	-2,1095%	1,4035	1,3939	1,4035	684	959,2489	3.678.573,5311
12-ago-2022	1,4239	-0,0037	-0,2615%	1,4092	1,3846	1,4239	5.326	7.493,6416	3.732.901,2354
11-ago-2022	1,4276	+0,0302	+2,1637 %	1,4028	1,3779	1,4376	9.378	13.287,4368	3.774.219,3432
10-ago-2022	1,3974	+0,0786	+5,9624 %	1,3377	1,3327	1,3974	8.118	11.161,2826	3.759.884,5431
09-ago-2022	1,3188	-0,0178	-1,3338%	1,3335	1,3188	1,3631	16.248	22.024,4070	3.709.395,0546
08-ago-2022	1,3366	+0,0274	+2,0918 %	1,3169	1,2971	1,3366	1.256	1.639,4251	3.739.995,5759
05-ago-2022	1,3092	-0,0308	-2,3002%	1,3288	1,2847	1,3288	3.801	4.992,6449	3.716.615,9802
04-ago-2022	1,3400	+0,0328	+2,5119 %	1,3400	1,3301	1,3648	2.326	3.127,0706	3.753.003,2685
03-ago-2022	1,3072	+0,0183	+1,4226 %	1,2925	1,2778	1,3072	2.504	3.255,7502	3.712.791,2452

Tabla 3. Muestra de las variables utilizadas. Fuente: REFINITIV EIKON.

ANEXO C: PUBLICACIONES EN REDES SOCIALES




Ilustración 35. Precios estimados de venta al público (antes de impuestos) para vehículos de pasajeros y furgonetas. Fuente: (BloombergNEF, 2021)

ANEXO D: PUBLICACIONES EN REDES SOCIALES




Ilustración 36. Composición de las publicaciones realizadas en la red social LinkedIn. Fuente: elaboración propia.